

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



NHẬN DẠNG THỰC THỂ TRONG VĂN
BẢN Y TẾ

Nhóm sinh viên thực hiện:

Nguyễn Công Việt	MSV: 23001953
Dương Văn Tài	MSV: 23001925
Vũ Khắc Huy Vinh	MSV: 23001956

HÀ NỘI – 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Nhóm sinh viên thực hiện:

Nguyễn Công Việt	MSV: 23001953
Dương Văn Tài	MSV: 23001925
Vũ Khắc Huy Vinh	MSV: 23001956

Named Entity Recognition in Medical Texts

Chuyên ngành: Khoa học máy tính và thông tin

Mã số: 27

NGƯỜI HƯỚNG DẪN KHOA HỌC:

ThS. Ngô Thế Quyền

HÀ NỘI – 2026

LỜI CAM ĐOAN

Tôi xin cam đoan các kết quả trình bày trong luận án là công trình nghiên cứu của bản thân nghiên cứu sinh trong thời gian học tập và nghiên cứu tại Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Hà Nội, dưới sự hướng dẫn của tập thể hướng dẫn khoa học. Các số liệu, kết quả trình bày trong luận án là hoàn toàn trung thực. Các kết quả sử dụng tham khảo đều đã được trích dẫn đầy đủ và theo đúng quy định.

Hà Nội, ngày 12 tháng 6 năm 2026

Nhóm sinh viên thực hiện:

Nguyễn Công Việt

Dương Văn Tài

Vũ Khắc Huy Vinh

LỜI CẢM ƠN

Trong quá trình thực hiện luận án, tôi xin gửi lời cảm ơn sâu sắc nhất tới thầy hướng dẫn của mình là **Ths. Ngô Thế Quyền**. Thầy luôn nhiệt tình chỉ dạy, định hướng, chia sẻ và động viên tôi rất nhiều. Tôi luôn cảm thấy trân trọng, biết ơn và ghi nhớ thời gian làm việc dưới sự hướng dẫn của thầy cô.

Hà Nội, ngày 12 tháng 6 năm 2026

Nhóm sinh viên thực hiện:

Nguyễn Công Việt

Dương Văn Tài

Vũ Khắc Huy Vinh

MỤC LỤC

LỜI CAM ĐOAN	i
LỜI CẢM ƠN	ii
MỤC LỤC	iii
DANH MỤC HÌNH VẼ	v
DANH MỤC BẢNG BIỂU	vi
CHƯƠNG 1. CƠ SỞ LÝ THUYẾT	5
1.1. Bài toán nhận dạng thực thể có tên	5
1.1.1. Khái niệm nhận dạng thực thể có tên	5
1.1.2. Biểu diễn thực thể theo token và span	6
1.1.3. Tiếp cận sinh trong bài toán NER	8
1.1.4. Ứng dụng của NER trong xử lý văn bản y tế	9
1.2. Đặc điểm của bài toán NER trong văn bản y tế tiếng Việt	10
1.2.1. Đặc thù ngôn ngữ y tế tiếng Việt	10
1.2.2. Sự khác biệt giữa văn bản mô tả bệnh lý và câu hỏi y khoa	11
1.3. Kỹ thuật tinh chỉnh mô hình ngôn ngữ lớn	12
1.3.1. Mô hình ngôn ngữ lớn	12
1.3.2. Instruction Tuning	14
1.3.3. Kỹ thuật Low-Rank Adaptation (LoRA)	15
1.3.4. Lượng tử hóa 4-bit và QLoRA	16
1.3.5. Precision, Recall và F1-score	18
1.4. Tổng kết chương	19
CHƯƠNG 2. CÁC HƯỚNG TIẾP CẬN TRONG BÀI TOÁN NHẬN DẠNG THỰC THỂ	21
2.1. Tổng quan quy trình hệ thống	21
2.2. Các bộ dữ liệu sử dụng trong nghiên cứu	22
2.2.1. Bộ dữ liệu ViMedNER	22

2.2.2. Bộ dữ liệu ViMQ	24
2.2.3. So sánh hai bộ dữ liệu	25
2.3. Lựa chọn mô hình và chiến lược tinh chỉnh	26
2.3.1. Mô hình Qwen2.5-3B-Instruct	26
2.3.2. Chiến lược huấn luyện các Adapter LoRA độc lập	26
2.4. Tối ưu hóa hậu xử lý dữ liệu	27
2.5. Các phương pháp đánh giá mô hình	28
2.5.1. Đánh giá NER dựa trên span thực thể	28
2.5.2. Đánh giá theo chuẩn BIO tagging với SeqEval	29
2.5.3. Đánh giá bằng mô hình ngôn ngữ lớn làm giám khảo (LLM-as-a-Judge)	30
2.6. Tổng kết chương	30
CHƯƠNG 3. Thực nghiệm bài toán	32
3.1. Cài đặt môi trường và công cụ thực nghiệm	32
3.1.1. Môi trường phần mềm và thư viện cốt lõi	32
3.2. Huấn luyện mô hình với kỹ thuật Quantized LoRA	33
3.2.1. Chi phí tham số và Cấu hình lượng hóa	33
3.2.2. Quy mô dữ liệu và Khởi tạo ngẫu nhiên	34
3.2.3. Giám sát quá trình hội tụ và Tối ưu hóa thuật toán	34
3.2.4. Hiệu năng phần cứng và Tính bền bỉ của hệ thống	34
3.2.5. Kết quả thực nghiệm trên bộ dữ liệu ViMQ	35
3.2.6. Thảo luận và Đánh giá so sánh	36
TÀI LIỆU THAM KHẢO	42

DANH MỤC HÌNH VẼ

2.1	Sơ đồ tổng quan quy trình nhận dạng thực thể y khoa	21
2.2	Mô tả cấu trúc một mẫu dữ liệu của bộ ViMedNER	23
2.3	Ví dụ một mẫu dữ liệu trong bộ dữ liệu ViMQ	24
3.1	Biểu đồ suy giảm hàm mất mát và biến thiên tốc độ học trong quá trình huấn luyện QLoRA	35
3.2	So sánh bộ chỉ số đánh giá Strict Metrics	37
3.3	So sánh bộ chỉ số đánh giá Relaxed Metrics	38
3.4	Biểu đồ phân bố chất lượng và các nhóm lỗi dự đoán thực thể của mô hình	39

DANH MỤC BẢNG

1.1	Ví dụ biểu diễn thực thể theo chuẩn BIO	7
1.2	Ví dụ dữ liệu dạng instruction–response	14
2.1	So sánh hai bộ dữ liệu ViMedNER và ViMQ	25
3.1	Phân bố kết quả và Chỉ số đánh giá trên tập ViMQ	35
3.2	Phân bố kết quả và Chỉ số đánh giá trên tập ViMedNER	36

MỞ ĐẦU

Trong những năm gần đây, sự phát triển mạnh mẽ của công nghệ số đã thúc đẩy việc lưu trữ và khai thác dữ liệu văn bản trong nhiều lĩnh vực, đặc biệt là lĩnh vực y tế. Các nguồn dữ liệu như hồ sơ bệnh án điện tử, đơn thuốc, kết quả xét nghiệm, ghi chú lâm sàng hay các báo cáo chuyên môn đều chứa lượng lớn thông tin quan trọng dưới dạng văn bản phi cấu trúc. Việc tự động trích xuất thông tin từ các nguồn dữ liệu này có ý nghĩa lớn trong việc hỗ trợ bác sĩ, giảm thời gian xử lý thủ công và tăng hiệu quả quản lý dữ liệu y tế.

Một trong những bài toán quan trọng trong xử lý ngôn ngữ tự nhiên là Named Entity Recognition (NER) – bài toán nhận dạng và gán nhãn các thực thể trong văn bản. Trong ngữ cảnh y tế, các thực thể này có thể bao gồm tên bệnh, triệu chứng, thuốc, liều lượng, chỉ số xét nghiệm, cơ quan bộ phận cơ thể, hoặc các thông tin lâm sàng khác. Nếu được trích xuất chính xác, các thực thể này có thể được sử dụng để xây dựng hệ thống hỗ trợ ra quyết định, hệ thống tìm kiếm thông tin y khoa, hoặc các nền tảng phân tích dữ liệu y tế quy mô lớn.

Tuy nhiên, bài toán NER y tế đặt ra nhiều thách thức hơn so với NER trong các miền dữ liệu thông thường. Dữ liệu y tế thường có nhiều thuật ngữ chuyên ngành, viết tắt, cách diễn đạt không thống nhất và phụ thuộc mạnh vào ngữ cảnh. Đặc biệt với tiếng Việt, việc thiếu các bộ dữ liệu gán nhãn quy mô lớn và chuẩn hóa khiến cho quá trình huấn luyện và đánh giá mô hình trở nên khó khăn hơn.

Giới thiệu bài toán

Bài toán trong dự án này là xây dựng một hệ thống nhận dạng thực thể có tên (Named Entity Recognition - NER) trên văn bản y tế tiếng Việt. Đầu vào của hệ thống là một đoạn văn bản y tế dưới dạng text được người dùng cung cấp trực tiếp. Hệ thống cần xử lý đoạn văn bản này theo từng câu để đảm bảo việc trích xuất thực thể được thực hiện chính xác và phù hợp với ngữ cảnh.

Trước khi đưa vào mô hình trích xuất thực thể, văn bản đầu vào sẽ được tách thành các câu riêng biệt. Sau đó, mỗi câu sẽ được phân loại để xác định thuộc luồng xử lý nào. Việc phân loại này đóng vai trò quan trọng vì trong dự án, hệ thống được thiết kế gồm hai luồng xử lý khác nhau, tương ứng với hai loại dữ liệu đầu vào khác nhau.

Cụ thể, hệ thống gồm hai luồng chính:

- **Luồng 1:** xử lý các câu thuộc nhóm dữ liệu bệnh lý y khoa. Các câu này sẽ được đưa vào mô hình `vimedner`.
- **Luồng 2:** xử lý các câu thuộc nhóm câu hỏi y khoa. Các câu này sẽ được đưa vào mô hình `vimq`.

Cách tổ chức theo hai luồng như trên giúp hệ thống lựa chọn mô hình phù hợp với từng loại dữ liệu, từ đó cải thiện chất lượng nhận dạng thực thể và làm cho kết quả đầu ra rõ ràng, dễ kiểm soát hơn. Sau khi được phân vào đúng luồng, mỗi câu sẽ được mô hình tương ứng xử lý để trích xuất các thực thể y khoa và trả về kết quả dưới dạng có cấu trúc.

Đây là một bài toán mang tính ứng dụng cao vì dữ liệu y tế thường được biểu diễn dưới dạng văn bản tự do, khó khai thác trực tiếp bằng các phương pháp truyền thống. Do đó, việc tự động hóa khâu trích xuất thực thể là một bước quan trọng trong việc chuyển đổi dữ liệu phi cấu trúc thành dữ liệu có cấu trúc.

Mục tiêu của đề tài

Mục tiêu của đề tài là xây dựng một pipeline NER y tế tiếng Việt có thể chạy ổn định trong môi trường tài nguyên hạn chế, đặc biệt là trên Google Colab với dung lượng VRAM khoảng 15GB. Để đạt được mục tiêu này, dự án lựa chọn mô hình nền tảng Qwen2.5-3B-Instruct và áp dụng kỹ thuật tinh chỉnh LoRA để giảm chi phí huấn luyện.

Đầu tiên, quy trình bắt đầu bằng việc chuẩn bị và chuẩn hóa dữ liệu phục vụ cho bài toán nhận dạng thực thể có tên (NER) trong lĩnh vực y tế tiếng Việt. Tiếp theo, đề tài tập trung vào việc huấn luyện hai adapter LoRA riêng biệt, tương ứng với hai hệ thống ontology khác nhau. Trong suốt quá trình này, hệ thống sẽ được tối ưu hóa để đảm bảo tính tương thích với môi trường Google

Colab, đồng thời quản lý hiệu quả tài nguyên nhằm tránh gây quá tải bộ nhớ. Sau khi hoàn tất huấn luyện, mô hình sẽ được đánh giá thông qua việc thực hiện inference trên tập dữ liệu kiểm thử. Cuối cùng, đề tài sẽ xây dựng một ứng dụng demo hoàn chỉnh với khả năng tiếp nhận văn bản đầu vào, tự động thực hiện tách câu, trích xuất các thực thể y tế và xuất kết quả đầu ra dưới định dạng JSON tiêu chuẩn.

Đối tượng và phạm vi nghiên cứu

Phạm vi nghiên cứu của đề tài tập trung vào việc xử lý văn bản y tế tiếng Việt dựa trên hai bộ dữ liệu `vimedner` và `vimq`. Về mặt phương pháp, đề tài sử dụng mô hình nền tảng `Qwen2.5-Instruct` và thực hiện huấn luyện hai adapter LoRA riêng biệt cho từng ontology thay vì tích hợp tất cả vào một mô hình duy nhất. Về phạm vi triển khai, nội dung nghiên cứu được giới hạn ở việc xây dựng chức năng xử lý văn bản đầu vào và trích xuất kết quả dưới định dạng có cấu trúc, chưa bao gồm việc phát triển giao diện ứng dụng hoàn chỉnh. Việc giới hạn phạm vi như trên giúp đề tài tập trung tối đa vào mục tiêu cốt lõi, đồng thời đảm bảo tính khả thi cao khi triển khai trên hạ tầng phần cứng có giới hạn về tài nguyên.

Hướng tiếp cận

Để giải quyết bài toán, đề tài lựa chọn cách tiếp cận dựa trên mô hình ngôn ngữ lớn kết hợp với kỹ thuật tinh chỉnh tham số hiệu quả. Cụ thể, mô hình `Qwen2.5-3B-Instruct` được sử dụng làm mô hình nền, sau đó được tinh chỉnh bằng LoRA để tạo ra các adapter chuyên biệt cho từng ontology.

Cách tiếp cận này mang lại nhiều ưu điểm vượt trội, tiêu biểu là việc giảm đáng kể lượng bộ nhớ tiêu thụ so với quá trình huấn luyện toàn bộ mô hình, khiến nó trở nên đặc biệt phù hợp với các môi trường bị hạn chế về tài nguyên điện toán như Colab. Bên cạnh đó, phương pháp này cung cấp khả năng xây dựng nhiều adapter chuyên biệt độc lập thay vì phải gộp toàn bộ nhân vào một mô hình duy nhất. Nhờ vậy, nó tạo ra sự linh hoạt tối đa, giúp người dùng dễ dàng tái sử dụng các adapter trong nhiều kịch bản inference khác nhau.

Bên cạnh đó, ở giai đoạn suy luận, hệ thống có thể sử dụng một cơ chế chọn

mô hình phù hợp theo loại đầu vào hoặc theo mục đích sử dụng, giúp đầu ra rõ ràng và phù hợp hơn với từng ngữ cảnh.

Ý nghĩa thực tiễn

Đề tài khẳng định ý nghĩa thực tiễn thông qua việc ứng dụng các kỹ thuật học máy hiện đại để khai thác dữ liệu y tế tiếng Việt, tạo nền tảng vững chắc cho nhiều ứng dụng quan trọng. Cụ thể, kết quả nghiên cứu góp phần tối ưu hóa công tác quản lý và xử lý dữ liệu thông qua việc tự động trích xuất thông tin từ hồ sơ bệnh án, đồng thời hỗ trợ hiệu quả cho các hoạt động phân tích và thống kê dữ liệu bệnh lý từ văn bản. Bên cạnh đó, đề tài còn đóng vai trò xây dựng hạ tầng cơ sở cho các hệ thống tìm kiếm y khoa chuyên biệt và hỗ trợ phát triển các công cụ trợ lý y tế thông minh, từ đó góp phần nâng cao hiệu suất trong quy trình làm việc lâm sàng. Ngoài ra, việc thiết lập thành công quy trình huấn luyện và suy luận ổn định trên nền tảng Google Colab cũng giúp đề tài đạt tính khả thi cao, đảm bảo khả năng tái hiện kết quả và tạo điều kiện thuận lợi cho việc mở rộng, phát triển trong các giai đoạn tiếp theo.

Chương 1

CƠ SỞ LÝ THUYẾT

Chương này trình bày các kiến thức nền tảng liên quan đến bài toán nhận dạng thực thể có tên trong văn bản y tế tiếng Việt. Nội dung bao gồm khái niệm và các cách biểu diễn thực thể, đặc điểm của dữ liệu y tế tiếng Việt, các bộ dữ liệu được sử dụng trong nghiên cứu, kỹ thuật tinh chỉnh mô hình ngôn ngữ lớn và các phương pháp đánh giá hệ thống.

1.1. Bài toán nhận dạng thực thể có tên

1.1.1. Khái niệm nhận dạng thực thể có tên

Nhận dạng thực thể có tên (Named Entity Recognition - NER) là một trong những bài toán cơ bản của lĩnh vực xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP). Mục tiêu của bài toán là tự động xác định các thực thể xuất hiện trong văn bản và gán cho chúng các nhãn ngữ nghĩa tương ứng. Tùy thuộc vào miền ứng dụng, các thực thể có thể thuộc nhiều loại khác nhau như tên người, tổ chức, địa danh, thời gian, hoặc các khái niệm chuyên ngành.

Trong quy trình khai phá thông tin từ dữ liệu văn bản, NER thường được xem là bước trung gian quan trọng giữa dữ liệu phi cấu trúc và dữ liệu có cấu trúc. Kết quả của bài toán không chỉ cho biết thực thể nào xuất hiện trong văn bản mà còn xác định chính xác vị trí của thực thể đó và loại thông tin mà nó biểu diễn. Nhờ vậy, các hệ thống xử lý ngôn ngữ có thể khai thác được những thông tin quan trọng phục vụ cho các tác vụ ở mức cao hơn như trích xuất quan hệ, xây dựng cơ sở tri thức, truy hồi thông tin hay hệ thống hỏi đáp thông minh.

Khác với bài toán phân loại văn bản, trong đó toàn bộ câu hoặc đoạn văn được gán một nhãn duy nhất, NER yêu cầu mô hình phải đồng thời thực hiện hai nhiệm vụ: xác định ranh giới của thực thể trong văn bản và phân loại thực thể đó vào đúng nhóm nhãn tương ứng. Một câu văn có thể chứa nhiều thực thể thuộc các loại khác nhau, do đó độ phức tạp của bài toán cao hơn đáng kể so với các tác vụ phân loại thông thường.

Trong lĩnh vực y tế, NER được sử dụng để nhận diện các thực thể chuyên ngành như tên bệnh, triệu chứng, thuốc, phương pháp điều trị, xét nghiệm hoặc thủ thuật y khoa. Chẳng hạn, với câu:

"Bệnh nhân được chẩn đoán viêm phổi và được chỉ định sử dụng amoxicillin."

Một hệ thống NER cần xác định cụm từ *viêm phổi* là thực thể thuộc nhóm bệnh lý, trong khi *amoxicillin* là thực thể thuộc nhóm thuốc điều trị. Kết quả nhận dạng giúp chuyển đổi câu văn tự nhiên thành dữ liệu có cấu trúc, tạo điều kiện thuận lợi cho các bước xử lý tiếp theo.

Trong những năm gần đây, cùng với sự phát triển mạnh mẽ của các mô hình học sâu và mô hình ngôn ngữ lớn, các phương pháp giải quyết bài toán NER đã có nhiều thay đổi. Các hệ thống truyền thống thường tiếp cận NER như một bài toán gán nhãn tuần tự, trong đó mỗi từ hoặc token trong câu được gán một nhãn biểu thị vai trò của nó đối với thực thể. Tuy nhiên, sự xuất hiện của các mô hình ngôn ngữ lớn đã mở ra hướng tiếp cận mới, trong đó bài toán NER được xem như một nhiệm vụ sinh văn bản có cấu trúc. Thay vì dự đoán nhãn cho từng token, mô hình có thể trực tiếp sinh ra danh sách các thực thể được phát hiện cùng với thông tin liên quan dưới dạng có cấu trúc như bảng hoặc JSON.

Trong nghiên cứu này, bài toán nhận dạng thực thể có tên được tiếp cận theo hướng sinh (Generative NER), sử dụng mô hình ngôn ngữ lớn để trích xuất các thực thể y tế từ văn bản tiếng Việt. Cách tiếp cận này cho phép tận dụng khả năng hiểu ngữ cảnh và tuân thủ chỉ dẫn của mô hình ngôn ngữ lớn, đồng thời tạo ra đầu ra linh hoạt và dễ dàng tích hợp với các hệ thống xử lý dữ liệu ở các bước tiếp theo.

1.1.2. Biểu diễn thực thể theo token và span

Để mô hình có thể học và dự đoán các thực thể trong văn bản, dữ liệu cần được biểu diễn dưới một dạng phù hợp. Trong bài toán nhận dạng thực thể có tên, hai cách biểu diễn phổ biến nhất là biểu diễn theo token và biểu diễn theo span thực thể. Mỗi cách biểu diễn phản ánh một góc nhìn khác nhau về bài toán và thường được sử dụng trong các hướng tiếp cận khác nhau.

Biểu diễn theo token xem bài toán NER như một nhiệm vụ gán nhãn tuần tự. Mỗi token trong câu được gán một nhãn thể hiện vai trò của nó đối với thực thể. Một trong những chuẩn biểu diễn phổ biến nhất là BIO (Beginning – Inside – Outside), trong đó nhãn B được sử dụng cho token đầu tiên của thực thể, nhãn I cho các token tiếp theo thuộc cùng thực thể và nhãn O cho các token không thuộc bất kỳ thực thể nào.

Ví dụ, với câu:

"Bệnh nhân bị viêm phổi và được điều trị bằng amoxicillin."

chuỗi nhãn BIO có thể được biểu diễn như trong Bảng ??.

Token	Nhãn
Bệnh	O
nhân	O
bị	O
viêm	B-DISEASE
phổi	I-DISEASE
và	O
được	O
điều	O
trị	O
bằng	O
amoxicillin	B-TREATMENT

Bảng 1.1: Ví dụ biểu diễn thực thể theo chuẩn BIO

Ưu điểm của biểu diễn theo token là phù hợp với các mô hình gán nhãn tuần tự truyền thống và là chuẩn đánh giá được sử dụng rộng rãi trong các bộ dữ liệu NER. Tuy nhiên, cách biểu diễn này phụ thuộc vào quá trình tách token và yêu cầu mô hình phải dự đoán nhãn cho từng token trong câu.

Bên cạnh đó, nhiều nghiên cứu hiện nay sử dụng biểu diễn theo span thực thể. Thay vì gán nhãn cho từng token, mỗi thực thể được mô tả trực tiếp thông qua vị trí bắt đầu, vị trí kết thúc và nhãn của thực thể trong văn bản. Một thực thể có thể được biểu diễn dưới dạng bộ ba:

$$(start, end, label)$$

Ví dụ, thực thể “viêm phổi” trong câu trên có thể được biểu diễn như sau:

$$(start = 14,; end = 22,; label = DISEASE)$$

Trong cách biểu diễn này, vị trí bắt đầu và kết thúc xác định phạm vi của thực thể trong văn bản, còn nhãn cho biết loại thực thể tương ứng. Thông tin văn bản của thực thể có thể được lưu kèm nhằm hỗ trợ quá trình kiểm tra và đánh giá kết quả.

Biểu diễn theo span đặc biệt phù hợp với các phương pháp NER dựa trên mô hình ngôn ngữ lớn. Thay vì dự đoán nhãn cho từng token, mô hình có thể trực tiếp sinh ra danh sách các thực thể được phát hiện cùng với thông tin vị trí và nhãn tương ứng. Cách tiếp cận này giúp đầu ra của hệ thống có cấu trúc rõ ràng, dễ dàng chuyển đổi sang các định dạng như JSON hoặc cơ sở dữ liệu.

Trong nghiên cứu này, dữ liệu thực thể được lưu trữ và xử lý chủ yếu dưới dạng span, bao gồm nội dung thực thể, vị trí xuất hiện và nhãn tương ứng. Dạng biểu diễn này phù hợp với hướng tiếp cận sinh thực thể bằng mô hình ngôn ngữ lớn được sử dụng trong hệ thống. Bên cạnh đó, để phục vụ cho việc đánh giá theo các chuẩn NER truyền thống, các span thực thể có thể được chuyển đổi sang chuỗi nhãn BIO trước khi tính toán các chỉ số đánh giá bằng thư viện SeqEval.

1.1.3. Tiếp cận sinh trong bài toán NER

Trong các hệ thống nhận dạng thực thể có tên truyền thống, bài toán NER thường được mô hình hóa như một nhiệm vụ gán nhãn tuần tự (sequence labeling). Mỗi token trong câu được gán một nhãn tương ứng theo các chuẩn như BIO hoặc BIOES, sau đó các token liên tiếp có cùng loại nhãn sẽ được ghép lại để tạo thành thực thể hoàn chỉnh. Cách tiếp cận này đã đạt được nhiều kết quả khả quan khi kết hợp với các mô hình học sâu như BiLSTM-CRF hoặc các mô hình Transformer chuyên biệt cho tác vụ gán nhãn.

Tuy nhiên, sự phát triển của các mô hình ngôn ngữ lớn (Large Language Models - LLMs) đã mở ra một hướng tiếp cận mới cho bài toán NER, được gọi là nhận dạng thực thể theo hướng sinh (Generative Named Entity Recognition). Thay vì dự đoán nhãn cho từng token trong câu, mô hình được yêu cầu trực tiếp sinh ra danh sách các thực thể được phát hiện từ văn bản đầu vào dưới dạng có cấu trúc.

Với cách tiếp cận này, đầu vào của mô hình là một câu hoặc đoạn văn bản cùng với một chỉ dẫn (instruction) mô tả nhiệm vụ cần thực hiện. Đầu ra là danh sách các thực thể được trích xuất kèm theo thông tin liên quan như loại thực thể, nội dung thực thể và vị trí xuất hiện trong văn bản. Ví dụ, với câu:

“Bệnh nhân được chẩn đoán viêm phổi và sử dụng amoxicillin.”

một mô hình Generative NER có thể sinh ra kết quả dưới dạng:

```
[ {"text": "viêm phổi", "label": "DISEASE", "text": "amoxicillin",  
  "label": "TREATMENT" } ]
```

Khác với phương pháp gán nhãn tuần tự, mô hình không cần thực hiện dự đoán ở cấp độ token mà trực tiếp tạo ra danh sách thực thể hoàn chỉnh. Nhờ đó, quá trình xây dựng hệ thống trở nên linh hoạt hơn và không phụ thuộc chặt chẽ vào định dạng nhãn BIO hoặc các kiến trúc giải mã chuyên biệt như Conditional Random Field (CRF).

Một ưu điểm quan trọng của Generative NER là khả năng tận dụng kiến thức ngôn ngữ và năng lực suy luận đã được học trong quá trình tiền huấn luyện của các mô hình ngôn ngữ lớn. Thông qua cơ chế instruction tuning, mô hình có thể hiểu yêu cầu bằng ngôn ngữ tự nhiên và thực hiện nhiều tác vụ khác nhau chỉ với sự thay đổi của câu lệnh hướng dẫn. Điều này đặc biệt hữu ích trong các miền dữ liệu chuyên ngành như y tế, nơi số lượng dữ liệu gán nhãn thường hạn chế và hệ thống cần thích nghi với nhiều tập nhãn khác nhau.

Bên cạnh những ưu điểm kể trên, hướng tiếp cận sinh cũng đặt ra một số thách thức. Do đầu ra được tạo dưới dạng văn bản tự do, mô hình có thể sinh ra kết quả không đúng định dạng mong muốn, bỏ sót thực thể hoặc xác định chưa chính xác ranh giới thực thể. Vì vậy, các nghiên cứu hiện nay thường kết hợp thêm các cơ chế kiểm tra định dạng và các phương pháp đánh giá chuyên biệt nhằm đảm bảo tính chính xác của kết quả trích xuất.

Trong nghiên cứu này, bài toán nhận dạng thực thể có tên được tiếp cận theo hướng sinh sử dụng mô hình ngôn ngữ lớn. Văn bản đầu vào được chuyển thành các cặp instruction–response để huấn luyện mô hình, trong khi đầu ra được biểu diễn dưới dạng danh sách thực thể có cấu trúc. Cách tiếp cận này phù hợp với khả năng tuân thủ chỉ dẫn của các mô hình ngôn ngữ lớn hiện đại và cho phép khai thác hiệu quả thông tin ngữ nghĩa trong văn bản y tế tiếng Việt.

1.1.4. Ứng dụng của NER trong xử lý văn bản y tế

Trong lĩnh vực y tế, phần lớn thông tin chuyên môn được lưu trữ dưới dạng văn bản tự nhiên như hồ sơ bệnh án điện tử, ghi chú lâm sàng, báo cáo xét nghiệm, đơn thuốc và các tài liệu hướng dẫn điều trị. Mặc dù chứa lượng lớn tri thức có giá trị, các nguồn dữ liệu này thường tồn tại dưới dạng phi cấu trúc, gây khó khăn cho việc lưu trữ, truy vấn và khai thác tự động. Nhận dạng thực thể có tên đóng vai trò quan trọng trong việc chuyển đổi các văn bản phi cấu trúc thành dữ liệu có cấu trúc thông qua quá trình tự động xác định và phân loại các thực thể y khoa quan trọng.

Một trong những ứng dụng phổ biến nhất của NER trong y tế là khai thác thông tin từ hồ sơ bệnh án điện tử. Thông qua việc nhận diện các thực thể như tên bệnh, triệu chứng, thuốc điều trị, kết quả xét nghiệm hoặc thủ thuật y khoa, hệ thống có thể tự động trích xuất các thông tin quan trọng từ các ghi chú lâm sàng của bác sĩ. Điều này giúp giảm đáng kể khối lượng công việc nhập liệu thủ công, đồng thời hỗ trợ chuẩn hóa dữ liệu phục vụ công tác quản lý và nghiên cứu y học.

NER cũng là thành phần nền tảng của các hệ thống hỏi đáp và tư vấn y tế thông minh. Khi tiếp nhận câu hỏi từ người dùng, hệ thống cần xác định chính xác các thực thể được đề cập, chẳng hạn như tên bệnh, triệu chứng hoặc thuốc, trước khi tiến hành truy xuất tri thức và sinh câu trả lời phù hợp. Khả năng nhận diện thực thể chính xác góp phần nâng cao chất lượng tương tác giữa người dùng và hệ thống, đồng thời cải thiện độ tin cậy của các kết quả tư vấn tự động.

Bên cạnh đó, NER được sử dụng rộng rãi trong các hệ thống trích xuất tri thức y khoa. Các thực thể được nhận diện từ số lượng lớn tài liệu chuyên ngành có thể được liên kết để xây dựng cơ sở tri thức hoặc đồ thị tri thức y học. Những nguồn tri thức này đóng vai trò quan trọng trong các ứng dụng như tìm kiếm thông tin y khoa, phân tích xu hướng dịch tễ học và hỗ trợ nghiên cứu khoa học.

Một ứng dụng quan trọng khác của NER là hỗ trợ ra quyết định lâm sàng. Bằng cách tự động xác định các thông tin liên quan đến bệnh lý, triệu chứng, tiền sử điều trị và thuốc sử dụng, hệ thống có thể cung cấp cho bác sĩ cái nhìn tổng quan về tình trạng bệnh nhân trong thời gian ngắn. Thông tin được chuẩn hóa từ bước nhận dạng thực thể còn có thể được sử dụng làm đầu vào cho các mô hình dự đoán nguy cơ bệnh tật, phát hiện tương tác thuốc hoặc đề xuất phác đồ điều trị phù hợp.

Sự phát triển của các mô hình ngôn ngữ lớn trong những năm gần đây tiếp

tục mở rộng phạm vi ứng dụng của NER trong y tế. Nhờ khả năng hiểu ngữ cảnh và xử lý ngôn ngữ tự nhiên ở mức độ sâu hơn, các hệ thống NER hiện đại có thể nhận diện thực thể chính xác hơn trên nhiều loại văn bản khác nhau, từ hồ sơ lâm sàng chuyên môn đến các câu hỏi sức khỏe của người dùng. Điều này tạo tiền đề cho việc xây dựng các hệ thống xử lý văn bản y tế tự động với độ chính xác và tính ứng dụng ngày càng cao.

1.2. Đặc điểm của bài toán NER trong văn bản y tế tiếng Việt

Việc nhận dạng thực thể có tên (Named Entity Recognition - NER) trong lĩnh vực y tế là một bài toán đầy thách thức, đòi hỏi hệ thống không chỉ hiểu được ngữ pháp mà còn phải nắm vững các kiến thức chuyên ngành sâu sắc. Để hiểu rõ hơn về các rào cản kỹ thuật mà đề tài cần giải quyết, dưới đây là phân tích chi tiết về những đặc thù riêng biệt của ngôn ngữ y tế tiếng Việt.

1.2.1. Đặc thù ngôn ngữ y tế tiếng Việt

So với các miền dữ liệu phổ thông như tin tức hoặc mạng xã hội, văn bản y tế tiếng Việt có nhiều đặc điểm riêng khiến bài toán nhận dạng thực thể trở nên khó khăn hơn. Những khó khăn này xuất phát từ tính chuyên ngành của lĩnh vực y học, đặc điểm ngôn ngữ tiếng Việt và sự đa dạng trong cách diễn đạt của người sử dụng.

Thuật ngữ chuyên ngành y tế.

Văn bản y tế chứa số lượng lớn các thuật ngữ chuyên môn liên quan đến bệnh lý, triệu chứng, thuốc, xét nghiệm và phương pháp điều trị. Nhiều thực thể có cấu trúc gồm nhiều từ liên tiếp như ‘suy tim sung huyết’, ‘viêm gan siêu vi B’ hoặc ‘chụp cộng hưởng từ’. Việc xác định chính xác ranh giới của các cụm từ này là một thách thức đối với hệ thống NER.

Sự xuất hiện của các từ viết tắt.

Trong hồ sơ bệnh án và các tài liệu y khoa, các từ viết tắt được sử dụng rất phổ biến nhằm giảm thời gian ghi chép. Ví dụ, ‘BN’ thường được dùng để chỉ bệnh nhân, ‘HA’ là huyết áp và ‘MRI’ là chụp cộng hưởng từ. Tuy nhiên, cùng một từ viết tắt có thể mang nhiều ý nghĩa khác nhau tùy thuộc vào ngữ cảnh, làm gia tăng độ khó của bài toán nhận dạng thực thể.

Hiện tượng đa nghĩa và phụ thuộc ngữ cảnh.

Nhiều thuật ngữ y khoa chỉ có thể được hiểu chính xác khi xét trong toàn bộ ngữ cảnh của câu. Một từ hoặc cụm từ có thể được xem là thực thể trong trường hợp này nhưng không phải thực thể trong trường hợp khác. Vì vậy, mô hình cần có khả năng khai thác thông tin ngữ nghĩa ở mức câu hoặc đoạn văn thay vì chỉ dựa vào các từ khóa riêng lẻ.

Khó khăn trong quá trình tách từ tiếng Việt.

Tiếng Việt sử dụng dấu cách để phân tách các tiếng thay vì các từ hoàn chỉnh. Trong khi đó, nhiều thực thể y khoa lại bao gồm nhiều tiếng ghép thành

một đơn vị ngữ nghĩa duy nhất. Nếu quá trình tách từ không chính xác, ranh giới thực thể có thể bị xác định sai, dẫn đến giảm hiệu quả nhận dạng.

Sự đa dạng trong cách diễn đạt.

Cùng một bệnh lý hoặc triệu chứng có thể được mô tả theo nhiều cách khác nhau. Chẳng hạn, một người dùng có thể sử dụng tên bệnh chính thức, trong khi người khác lại mô tả thông qua các biểu hiện lâm sàng hoặc cách gọi thông dụng. Điều này làm tăng tính đa dạng của dữ liệu và đòi hỏi mô hình phải có khả năng khái quát hóa tốt trên nhiều kiểu diễn đạt khác nhau.

Những đặc điểm trên khiến bài toán NER trong văn bản y tế tiếng Việt trở nên phức tạp hơn so với nhiều miền dữ liệu khác. Do đó, các hệ thống hiện đại thường tận dụng khả năng hiểu ngữ cảnh của các mô hình ngôn ngữ lớn nhằm nâng cao chất lượng nhận dạng thực thể.

1.2.2. Sự khác biệt giữa văn bản mô tả bệnh lý và câu hỏi y khoa

Trong lĩnh vực y tế, dữ liệu văn bản có thể xuất hiện dưới nhiều hình thức khác nhau tùy thuộc vào mục đích sử dụng. Trong nghiên cứu này, hai dạng văn bản được xem xét là văn bản mô tả bệnh lý và câu hỏi y khoa. Mặc dù đều thuộc miền y tế, hai loại dữ liệu này có những đặc điểm ngôn ngữ và ngữ cảnh khác nhau, dẫn đến những thách thức riêng đối với bài toán nhận dạng thực thể.

Văn bản mô tả bệnh lý có ngữ cảnh đầy đủ và giàu thông tin.

Văn bản mô tả bệnh lý thường xuất hiện trong các tài liệu y khoa, báo cáo bệnh án hoặc các đoạn mô tả tình trạng sức khỏe của bệnh nhân. Những văn bản này thường có độ dài tương đối lớn, chứa nhiều thông tin liên quan đến triệu chứng, nguyên nhân, chẩn đoán và phương pháp điều trị. Do được trình bày dưới dạng mô tả liên tục nên ngữ cảnh của các thực thể thường khá đầy đủ, giúp mô hình có nhiều thông tin hơn để đưa ra quyết định nhận dạng.

Ví dụ, trong một đoạn mô tả bệnh lý, thực thể bệnh có thể xuất hiện cùng với triệu chứng, kết quả chẩn đoán và phương pháp điều trị tương ứng. Sự liên kết giữa các thực thể trong cùng một ngữ cảnh giúp việc xác định loại thực thể trở nên thuận lợi hơn.

Câu hỏi y khoa thường ngắn gọn và thiếu ngữ cảnh.

Khác với văn bản mô tả bệnh lý, câu hỏi y khoa thường được viết dưới dạng câu hỏi của người dùng trên các diễn đàn sức khỏe hoặc hệ thống tư vấn trực tuyến. Các câu hỏi này có xu hướng ngắn hơn, tập trung trực tiếp vào vấn đề cần giải đáp và thường không cung cấp đầy đủ thông tin nền.

Ví dụ, một người dùng có thể đặt câu hỏi như: “Uống amoxicillin khi mang thai có an toàn không?” hoặc “Đau ngực kéo dài có phải dấu hiệu bệnh tim không?”. Trong những trường hợp này, số lượng thực thể xuất hiện không nhiều nhưng ngữ cảnh hỗ trợ cho việc phân loại thực thể lại khá hạn chế. Điều này làm tăng độ khó của quá trình nhận dạng.

Sự khác biệt về mật độ và phân bố thực thể.

Trong văn bản mô tả bệnh lý, một câu hoặc một đoạn văn có thể chứa đồng thời nhiều loại thực thể khác nhau như bệnh lý, triệu chứng, nguyên nhân, xét nghiệm và phương pháp điều trị. Ngược lại, câu hỏi y khoa thường chỉ tập trung vào một hoặc một vài thực thể liên quan trực tiếp đến vấn đề mà người dùng quan tâm.

Do đó, mô hình phải thích nghi với hai kiểu phân bố thực thể khác nhau. Đối với văn bản mô tả bệnh lý, thách thức nằm ở việc nhận diện đầy đủ các thực thể trong ngữ cảnh dài. Trong khi đó, đối với câu hỏi y khoa, thách thức chủ yếu đến từ việc suy luận đúng loại thực thể khi lượng thông tin ngữ cảnh còn hạn chế.

Sự khác biệt về hệ nhãn thực thể.

Hai loại dữ liệu cũng thường được xây dựng với các mục tiêu khai thác thông tin khác nhau nên hệ nhãn thực thể có thể không hoàn toàn giống nhau. Văn bản mô tả bệnh lý thường chú trọng các nhóm thực thể liên quan đến bệnh, triệu chứng, nguyên nhân và điều trị. Trong khi đó, dữ liệu hỏi đáp y khoa thường tập trung vào các thực thể xuất hiện phổ biến trong nhu cầu tra cứu của người dùng như bệnh lý, thuốc hoặc thủ thuật y khoa.

Những khác biệt về cấu trúc ngôn ngữ, mức độ ngữ cảnh và hệ nhãn thực thể cho thấy bài toán NER trong văn bản y tế không phải là một tác vụ đồng nhất. Việc đánh giá mô hình trên cả văn bản mô tả bệnh lý và câu hỏi y khoa giúp phản ánh đầy đủ hơn khả năng thích nghi của hệ thống đối với các tình huống sử dụng khác nhau trong thực tế.

1.3. Kỹ thuật tinh chỉnh mô hình ngôn ngữ lớn

Sự bùng nổ của các mô hình ngôn ngữ lớn (LLM) đã mang lại những bước tiến đột phá trong lĩnh vực xử lý ngôn ngữ tự nhiên. Tuy nhiên, đối với các miền tri thức chuyên sâu và đòi hỏi độ chính xác khắt khe như y khoa, việc áp dụng nguyên bản các mô hình tổng quát thường không đạt hiệu quả tối ưu, đòi hỏi sự can thiệp của các kỹ thuật tinh chỉnh (fine-tuning). Nội dung phần này sẽ trình bày tổng quan về cơ sở nền tảng của các mô hình ngôn ngữ lớn, từ đó tạo tiền đề vững chắc để đi sâu phân tích các phương pháp tinh chỉnh hiệu quả, giúp mô hình thích ứng tốt với bài toán đặt ra trong điều kiện ràng buộc về tài nguyên tính toán.

1.3.1. Mô hình ngôn ngữ lớn

Mô hình ngôn ngữ lớn (Large Language Model – LLM) là các mô hình học sâu được huấn luyện trên khối lượng dữ liệu văn bản rất lớn nhằm học cách biểu diễn và sinh ngôn ngữ tự nhiên. Thông qua quá trình huấn luyện tự giám sát, mô hình học được các quy luật ngữ pháp, ngữ nghĩa và mối quan hệ giữa các từ trong ngữ cảnh, từ đó có khả năng thực hiện nhiều tác vụ xử lý ngôn ngữ

tự nhiên khác nhau như tóm tắt văn bản, dịch máy, trả lời câu hỏi, trích xuất thông tin và sinh nội dung.

Kiến trúc Transformer Decoder.

Phần lớn các mô hình ngôn ngữ lớn hiện nay được xây dựng dựa trên kiến trúc Transformer. Đối với các mô hình sinh văn bản như GPT, LLaMA hay Qwen, kiến trúc được sử dụng chủ yếu là Transformer Decoder.

Transformer Decoder bao gồm nhiều lớp tự chú ý (Self-Attention) và mạng truyền thẳng (Feed-Forward Network) được xếp chồng lên nhau. Cơ chế Self-Attention cho phép mô hình xác định mức độ liên quan giữa các từ trong câu, từ đó xây dựng được biểu diễn ngữ cảnh phong phú cho từng token. Nhờ khả năng xử lý quan hệ phụ thuộc dài hạn, Transformer khắc phục được nhiều hạn chế của các kiến trúc tuần tự truyền thống như RNN hay LSTM.

Trong quá trình sinh văn bản, mô hình dự đoán token tiếp theo dựa trên toàn bộ chuỗi token đã xuất hiện trước đó. Quá trình này được thực hiện lặp lại cho đến khi tạo ra câu trả lời hoàn chỉnh.

Khả năng sinh văn bản.

Khác với các mô hình được thiết kế riêng cho từng tác vụ, LLM tiếp cận bài toán dưới dạng sinh văn bản. Mô hình nhận đầu vào là một đoạn ngữ cảnh hoặc một yêu cầu bằng ngôn ngữ tự nhiên và sinh ra chuỗi văn bản tương ứng làm đầu ra.

Đặc điểm này cho phép cùng một mô hình có thể thực hiện nhiều nhiệm vụ khác nhau mà không cần thay đổi kiến trúc. Trong bài toán nhận dạng thực thể có tên, thay vì dự đoán nhãn cho từng token, mô hình có thể được yêu cầu sinh trực tiếp danh sách thực thể dưới dạng văn bản có cấu trúc. Cách tiếp cận này giúp đơn giản hóa quá trình thiết kế hệ thống và tận dụng tốt khả năng suy luận ngữ nghĩa của mô hình.

Khả năng tuân theo chỉ dẫn (Instruction Following).

Một đặc điểm quan trọng của các LLM hiện đại là khả năng tuân theo chỉ dẫn (Instruction Following). Sau giai đoạn tiền huấn luyện trên dữ liệu quy mô lớn, mô hình tiếp tục được tinh chỉnh trên các tập dữ liệu chứa cặp chỉ dẫn – phản hồi nhằm học cách thực hiện các yêu cầu cụ thể của người dùng.

Nhờ đó, mô hình có thể hiểu và thực hiện nhiều loại nhiệm vụ khác nhau chỉ thông qua một câu lệnh bằng ngôn ngữ tự nhiên. Ví dụ, người dùng có thể yêu cầu mô hình tóm tắt văn bản, dịch ngôn ngữ hoặc trích xuất thực thể từ một câu y khoa mà không cần xây dựng các bộ phân loại chuyên biệt cho từng tác vụ.

Khả năng tuân theo chỉ dẫn là nền tảng cho hướng tiếp cận NER dạng sinh được sử dụng trong nghiên cứu này. Thay vì dự đoán nhãn theo từng token, mô hình được cung cấp một hướng dẫn mô tả nhiệm vụ và sinh ra danh sách thực thể cùng loại thực thể tương ứng dưới dạng có cấu trúc.

1.3.2. Instruction Tuning

Instruction Tuning là kỹ thuật tinh chỉnh mô hình ngôn ngữ lớn nhằm giúp mô hình hiểu và thực hiện các yêu cầu được mô tả dưới dạng chỉ dẫn bằng ngôn ngữ tự nhiên. Sau giai đoạn tiền huấn luyện trên lượng dữ liệu văn bản quy mô lớn, mô hình tiếp tục được huấn luyện trên các cặp dữ liệu gồm chỉ dẫn đầu vào và phản hồi mong muốn. Quá trình này giúp mô hình học cách diễn giải yêu cầu của người dùng và tạo ra đầu ra phù hợp với nhiệm vụ được giao.

Dữ liệu dạng instruction–response.

Trong Instruction Tuning, mỗi mẫu dữ liệu thường bao gồm hai thành phần chính là phần chỉ dẫn (*instruction*) và phần phản hồi (*response*). Chỉ dẫn mô tả nhiệm vụ mà mô hình cần thực hiện, trong khi phản hồi là kết quả mong muốn tương ứng với chỉ dẫn đó.

Ví dụ, đối với bài toán nhận dạng thực thể có tên trong văn bản y tế, chỉ dẫn có thể yêu cầu mô hình xác định các thực thể xuất hiện trong câu và trả về kết quả dưới dạng JSON. Khi đó, phản hồi sẽ là danh sách các thực thể cùng loại thực thể tương ứng.

Thành phần	Nội dung
Instruction	Hãy nhận dạng các thực thể y khoa trong câu sau và trả về kết quả dưới dạng JSON.
Input	Bệnh nhân được chẩn đoán viêm phổi và điều trị bằng amoxicillin.
Response	{"viêm phổi": DISEASE, "amoxicillin": DRUG}

Bảng 1.2: Ví dụ dữ liệu dạng instruction–response

Thông qua việc quan sát số lượng lớn các cặp instruction–response, mô hình dần học được cách ánh xạ từ yêu cầu đầu vào sang định dạng đầu ra mong muốn mà không cần thiết kế riêng một kiến trúc cho từng tác vụ.

Vai trò của Instruction Tuning.

Instruction Tuning đóng vai trò quan trọng trong việc điều chỉnh hành vi của mô hình ngôn ngữ lớn. Nếu chỉ được tiền huấn luyện bằng mục tiêu dự đoán token tiếp theo, mô hình có thể tạo ra văn bản đúng ngữ pháp nhưng không nhất thiết đáp ứng chính xác yêu cầu của người dùng. Quá trình Instruction Tuning giúp mô hình học cách tuân theo hướng dẫn, duy trì định dạng đầu ra và tập trung vào nhiệm vụ được chỉ định.

Đối với bài toán NER theo hướng sinh, khả năng tuân theo chỉ dẫn đặc biệt quan trọng vì mô hình không còn thực hiện phân loại token như các phương pháp truyền thống. Thay vào đó, mô hình cần hiểu yêu cầu nhận dạng thực thể, xác định các thực thể trong văn bản và sinh kết quả dưới dạng có cấu trúc. Nhờ Instruction Tuning, mô hình có thể thực hiện toàn bộ quy trình này thông qua

một lời nhắc duy nhất, đồng thời duy trì tính linh hoạt khi áp dụng cho nhiều miền dữ liệu khác nhau.

Instruction Tuning hiện là một trong những thành phần cốt lõi của các mô hình ngôn ngữ lớn hiện đại như GPT, LLaMA-Instruct và Qwen2.5-Instruct, góp phần nâng cao đáng kể khả năng tương tác và giải quyết nhiệm vụ của mô hình trong các ứng dụng thực tế.

1.3.3. Kỹ thuật Low-Rank Adaptation (LoRA)

Sự phát triển của các mô hình ngôn ngữ lớn mang lại hiệu quả cao cho nhiều bài toán xử lý ngôn ngữ tự nhiên. Tuy nhiên, việc tinh chỉnh toàn bộ tham số của mô hình (full fine-tuning) đòi hỏi lượng lớn tài nguyên tính toán và bộ nhớ lưu trữ. Đối với các mô hình có hàng tỷ tham số, chi phí huấn luyện và triển khai thường vượt quá khả năng của các hệ thống phần cứng phổ thông.

Để giải quyết vấn đề này, Hu và cộng sự đã đề xuất phương pháp *Low-Rank Adaptation* (LoRA), cho phép tinh chỉnh mô hình với số lượng tham số cần cập nhật nhỏ hơn rất nhiều so với phương pháp huấn luyện toàn bộ mô hình. Ý tưởng cốt lõi của LoRA là giữ nguyên các trọng số đã được huấn luyện trước và chỉ bổ sung một lượng nhỏ tham số mới để mô hình thích nghi với tác vụ cụ thể.

Nguyên lý của LoRA.

Giả sử một lớp tuyến tính trong mô hình có ma trận trọng số ban đầu là W . Trong phương pháp fine-tuning truyền thống, toàn bộ ma trận W sẽ được cập nhật trong quá trình huấn luyện. Ngược lại, LoRA giữ cố định W và bổ sung một ma trận hiệu chỉnh ΔW có hạng thấp (low-rank), sao cho:

$$W' = W + \Delta W$$

Trong đó, ΔW được phân rã thành tích của hai ma trận hạng thấp B và A :

$$W' = W + BA$$

với $A \in \mathbb{R}^{r \times d}$, $B \in \mathbb{R}^{k \times r}$ và r là hạng của phép phân rã, thường có giá trị rất nhỏ so với kích thước của ma trận trọng số gốc. Trong quá trình huấn luyện, chỉ các tham số của hai ma trận A và B được cập nhật, trong khi ma trận W vẫn được giữ nguyên.

Nhờ biểu diễn dưới dạng ma trận hạng thấp, số lượng tham số cần học giảm đáng kể nhưng vẫn duy trì được khả năng thích nghi của mô hình đối với nhiệm vụ mới.

Giảm số lượng tham số huấn luyện.

Một trong những lợi ích quan trọng nhất của LoRA là giảm đáng kể số lượng tham số cần cập nhật. Thay vì huấn luyện toàn bộ hàng tỷ tham số của mô hình, LoRA chỉ yêu cầu huấn luyện các ma trận hạng thấp được bổ sung vào một số lớp tuyến tính nhất định, thường là các lớp attention.

Điều này giúp giảm nhu cầu bộ nhớ GPU, rút ngắn thời gian huấn luyện và giảm kích thước của mô hình được lưu sau khi tinh chỉnh. Trong nhiều trường hợp, số lượng tham số huấn luyện chỉ chiếm một tỷ lệ rất nhỏ so với tổng số tham số của mô hình gốc.

Ưu điểm của LoRA.

LoRA mang lại nhiều lợi ích trong quá trình tinh chỉnh mô hình ngôn ngữ lớn:

- Giảm đáng kể số lượng tham số cần huấn luyện.
- Tiết kiệm bộ nhớ GPU và chi phí tính toán.
- Giữ nguyên tri thức đã học của mô hình tiền huấn luyện.
- Cho phép lưu trữ và chuyển đổi giữa nhiều bộ tham số tinh chỉnh khác nhau mà không cần lưu lại toàn bộ mô hình.
- Dễ dàng kết hợp với các kỹ thuật tối ưu bộ nhớ khác như lượng tử hóa. ““

Hạn chế của LoRA.

Bên cạnh những ưu điểm nổi bật, LoRA vẫn tồn tại một số hạn chế nhất định. Do chỉ cập nhật một phần nhỏ tham số nên khả năng thích nghi của mô hình có thể bị giới hạn đối với các tác vụ đòi hỏi thay đổi lớn về tri thức hoặc hành vi. Hiệu quả của LoRA cũng phụ thuộc vào việc lựa chọn hạng (r) và vị trí chèn adapter trong kiến trúc mô hình.

Ngoài ra, mặc dù LoRA giúp giảm đáng kể chi phí huấn luyện, mô hình gốc vẫn cần được tải vào bộ nhớ trong quá trình suy luận. Vì vậy, đối với các mô hình rất lớn, yêu cầu tài nguyên phần cứng vẫn là một yếu tố cần được cân nhắc.

Nhờ khả năng giảm chi phí huấn luyện trong khi vẫn duy trì hiệu năng cao, LoRA hiện là một trong những phương pháp tinh chỉnh tham số hiệu quả và được sử dụng rộng rãi trong các nghiên cứu liên quan đến mô hình ngôn ngữ lớn. Đây cũng là nền tảng của kỹ thuật QLoRA được trình bày trong phần tiếp theo.

1.3.4. Lượng tử hóa 4-bit và QLoRA

Mặc dù kỹ thuật LoRA giúp giảm đáng kể số lượng tham số cần huấn luyện, việc tải toàn bộ mô hình ngôn ngữ lớn vào bộ nhớ vẫn đòi hỏi lượng tài nguyên đáng kể. Đối với các mô hình có hàng tỷ tham số, chỉ riêng việc lưu trữ trọng số dưới định dạng số thực 16-bit hoặc 32-bit cũng có thể vượt quá khả năng của các GPU phổ thông.

Để giải quyết vấn đề này, các kỹ thuật lượng tử hóa được sử dụng nhằm giảm dung lượng lưu trữ của mô hình bằng cách biểu diễn trọng số với số lượng bit nhỏ hơn. Một trong những phương pháp được sử dụng rộng rãi hiện nay là lượng

tử hóa 4-bit kết hợp với LoRA, được gọi là *Quantized Low-Rank Adaptation* (QLoRA).

Lượng tử hóa mô hình.

Lượng tử hóa là quá trình chuyển đổi các trọng số của mô hình từ biểu diễn có độ chính xác cao sang biểu diễn có độ chính xác thấp hơn. Thay vì lưu mỗi trọng số bằng 16 hoặc 32 bit, các giá trị được ánh xạ sang một tập hữu hạn các mức lượng tử hóa.

Việc giảm số lượng bit sử dụng cho mỗi trọng số giúp tiết kiệm đáng kể bộ nhớ và băng thông truyền dữ liệu trong quá trình huấn luyện cũng như suy luận. Tuy nhiên, nếu thực hiện không phù hợp, lượng tử hóa có thể làm suy giảm chất lượng của mô hình do mất mát thông tin.

Trong QLoRA, trọng số của mô hình được lưu dưới định dạng 4-bit nhằm giảm tối đa dung lượng bộ nhớ mà vẫn duy trì hiệu năng ở mức chấp nhận được.

Normal Float 4 (NF4).

Một thách thức của lượng tử hóa 4-bit là số lượng giá trị biểu diễn rất hạn chế. Để khắc phục điều này, Dettmers và cộng sự đề xuất định dạng *Normal Float 4* (NF4), được thiết kế riêng cho các trọng số của mạng nơ-ron.

NF4 giả định rằng các trọng số của mô hình có phân bố gần với phân bố chuẩn (Gaussian Distribution). Dựa trên đặc điểm này, các mức lượng tử hóa được phân bố không đồng đều nhằm biểu diễn chính xác hơn những vùng có mật độ trọng số cao.

Nhờ đó, NF4 có khả năng bảo toàn thông tin tốt hơn so với các phương pháp lượng tử hóa tuyến tính truyền thống khi sử dụng cùng số lượng bit biểu diễn.

Double Quantization.

Bên cạnh việc lượng tử hóa các trọng số của mô hình, QLoRA còn áp dụng kỹ thuật *Double Quantization*. Trong phương pháp này, các hệ số được sử dụng để thực hiện lượng tử hóa cũng tiếp tục được lượng tử hóa một lần nữa.

Ý tưởng này giúp giảm thêm lượng bộ nhớ cần thiết để lưu trữ các tham số phụ trợ mà không làm ảnh hưởng đáng kể đến hiệu năng của mô hình. Nhờ Double Quantization, mức tiêu thụ bộ nhớ tiếp tục được tối ưu hóa so với các phương pháp lượng tử hóa thông thường.

Kết hợp LoRA và lượng tử hóa 4-bit.

QLoRA là sự kết hợp giữa hai kỹ thuật: lượng tử hóa 4-bit và LoRA. Trong phương pháp này, các trọng số của mô hình tiền huấn luyện được lưu dưới dạng 4-bit và được giữ cố định trong suốt quá trình huấn luyện. Các adapter LoRA được chèn vào mô hình và chỉ các tham số của adapter mới được cập nhật.

Nhờ cách tiếp cận này, mô hình vừa tận dụng được ưu điểm tiết kiệm bộ nhớ của lượng tử hóa, vừa duy trì khả năng thích nghi với tác vụ mới thông qua LoRA. Toàn bộ quá trình huấn luyện chỉ yêu cầu cập nhật một lượng nhỏ tham số trong khi mô hình gốc vẫn được giữ nguyên.

Lợi ích của QLoRA.

QLoRA mang lại nhiều lợi ích trong quá trình tinh chỉnh mô hình ngôn ngữ lớn:

- Giảm đáng kể lượng bộ nhớ GPU cần thiết để tải mô hình.
- Cho phép huấn luyện các mô hình có hàng tỷ tham số trên phần cứng có tài nguyên hạn chế.
- Duy trì hiệu năng gần tương đương với các phương pháp fine-tuning truyền thống.
- Giảm chi phí lưu trữ và chi phí tính toán trong quá trình huấn luyện.
- Có thể kết hợp linh hoạt với các kỹ thuật tối ưu hóa khác trong hệ sinh thái mô hình ngôn ngữ lớn.

Nhờ khả năng tiết kiệm bộ nhớ nhưng vẫn bảo toàn hiệu quả học tập của mô hình, QLoRA hiện là một trong những phương pháp tinh chỉnh tham số phổ biến nhất đối với các mô hình ngôn ngữ lớn. Trong nghiên cứu này, kỹ thuật QLoRA được sử dụng để tinh chỉnh mô hình Qwen2.5-3B-Instruct trên bài toán nhận dạng thực thể có tên trong văn bản y tế tiếng Việt.

1.3.5. Precision, Recall và F1-score

Để đánh giá hiệu quả của hệ thống nhận dạng thực thể có tên, nghiên cứu sử dụng ba chỉ số phổ biến là Precision, Recall và F1-score. Các chỉ số này phản ánh khả năng nhận diện chính xác thực thể, mức độ bao phủ các thực thể cần phát hiện và hiệu năng tổng thể của mô hình.

Trong bài toán NER, kết quả dự đoán của mô hình được so sánh với nhãn tham chiếu (ground truth). Từ đó xác định ba đại lượng cơ bản gồm True Positive (TP), False Positive (FP) và False Negative (FN).

TP là số lượng thực thể được mô hình nhận dạng đúng. Một thực thể được xem là đúng khi nhãn thực thể và vị trí của thực thể phù hợp với dữ liệu tham chiếu theo tiêu chí đánh giá được lựa chọn.

FP là số lượng thực thể được mô hình dự đoán nhưng không tồn tại trong dữ liệu tham chiếu hoặc được gán sai nhãn.

FN là số lượng thực thể có trong dữ liệu tham chiếu nhưng không được mô hình phát hiện.

Precision.

Precision đo tỷ lệ thực thể được dự đoán đúng trên tổng số thực thể mà mô hình dự đoán.

$$Precision = \frac{TP}{TP + FP}$$

Giá trị Precision cao cho thấy phần lớn các thực thể được mô hình dự đoán là chính xác.

Recall.

Recall đo tỷ lệ thực thể được nhận diện đúng trên tổng số thực thể thực sự tồn tại trong dữ liệu.

$$Recall = \frac{TP}{TP + FN}$$

Recall cao cho thấy mô hình có khả năng phát hiện được phần lớn các thực thể cần nhận dạng.

F1-score.

F1-score là trung bình điều hòa giữa Precision và Recall, được sử dụng để đánh giá tổng thể hiệu năng của mô hình.

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Chỉ số F1-score đặc biệt hữu ích trong các bài toán có phân bố nhãn không cân bằng, bởi nó đồng thời xem xét cả độ chính xác và độ bao phủ của mô hình.

Trong nghiên cứu này, Precision, Recall và F1-score được sử dụng làm các chỉ số đánh giá chính cho hệ thống nhận dạng thực thể có tên. Các chỉ số này được tính toán trên nhiều phương pháp đánh giá khác nhau, bao gồm đánh giá khớp chính xác (Strict Match), đánh giá khớp một phần (Relaxed Match), đánh giá theo chuẩn BIO bằng thư viện *segeval* và đánh giá ngữ nghĩa thông qua phương pháp *LLM-as-a-Judge*.

1.4. Tổng kết chương

Chương này đã trình bày những cơ sở lý thuyết làm nền tảng cho nghiên cứu nhận dạng thực thể có tên trong văn bản y tế tiếng Việt. Trước hết, các khái niệm cơ bản của bài toán NER đã được giới thiệu, bao gồm các phương pháp biểu diễn thực thể theo token và span, cũng như xu hướng tiếp cận sinh (Generative NER) đang được áp dụng rộng rãi cùng sự phát triển của các mô hình ngôn ngữ lớn.

Bên cạnh đó, chương đã phân tích những đặc trưng của văn bản y tế tiếng Việt, từ hệ thống thuật ngữ chuyên ngành, hiện tượng viết tắt, đa nghĩa cho đến sự khác biệt giữa văn bản mô tả bệnh lý và câu hỏi y khoa. Những đặc điểm này tạo nên các thách thức đặc thù đối với quá trình nhận dạng và phân loại thực thể trong miền dữ liệu y tế.

Hai bộ dữ liệu ViMedNER và ViMQ cũng đã được giới thiệu như những nguồn dữ liệu đại diện cho hai ngữ cảnh ứng dụng khác nhau của bài toán NER y tế. Việc sử dụng đồng thời hai bộ dữ liệu giúp đánh giá khả năng thích nghi của mô hình trên các kiểu văn bản và hệ nhãn thực thể khác nhau.

Về phương diện mô hình, chương đã trình bày các khái niệm liên quan đến mô hình ngôn ngữ lớn, cơ chế Instruction Tuning, cùng các kỹ thuật tinh chỉnh hiệu quả tham số như LoRA và QLoRA. Những kỹ thuật này tạo cơ sở cho việc

khai thác mô hình Qwen2.5-3B-Instruct nhằm xây dựng hệ thống nhận dạng thực thể với chi phí tính toán phù hợp nhưng vẫn đảm bảo chất lượng dự đoán.

Cuối cùng, các phương pháp đánh giá được sử dụng trong nghiên cứu đã được giới thiệu, bao gồm đánh giá dựa trên span thực thể, đánh giá theo chuẩn BIO với SeqEval và phương pháp LLM-as-a-Judge. Sự kết hợp giữa các phương pháp này cho phép đánh giá mô hình ở cả mức độ khớp hình thức và mức độ tương đồng ngữ nghĩa.

Những cơ sở lý thuyết được trình bày trong chương là nền tảng cho việc xây dựng và triển khai hệ thống nhận dạng thực thể có tên trong văn bản y tế tiếng Việt. Trên cơ sở đó, chương tiếp theo sẽ trình bày chi tiết phương pháp nghiên cứu, quy trình xử lý dữ liệu, thiết kế thực nghiệm và quá trình tinh chỉnh mô hình Qwen2.5-3B-Instruct cho bài toán được đặt ra.


Chương 2

CÁC HƯỚNG TIẾP CẬN TRONG BÀI TOÁN NHẬN DẠNG THỰC THỂ

Chương này trình bày chi tiết về phương pháp và quy trình kỹ thuật được đề xuất để giải quyết bài toán nhận dạng thực thể có tên trong văn bản y tế tiếng Việt. Nội dung bao gồm việc phân tích các đặc trưng của dữ liệu đầu vào, lý do lựa chọn mô hình nền tảng, thiết kế quy trình tinh chỉnh hệ thống, cũng như các kỹ thuật hậu xử lý và phương pháp đánh giá nhằm đảm bảo độ chính xác tối đa cho kết quả đầu ra.

2.1. Tổng quan quy trình hệ thống

Để giải quyết bài toán nhận dạng thực thể y tế bằng mô hình sinh văn bản, nghiên cứu đề xuất một quy trình hệ thống khép kín bao gồm bốn giai đoạn cốt lõi: tiền xử lý dữ liệu, suy luận qua mô hình ngôn ngữ, hậu xử lý kết quả và đánh giá hiệu năng. Luồng dữ liệu đi qua các giai đoạn này được thiết kế có tính liên kết chặt chẽ nhằm tối ưu hóa khả năng hiểu ngữ cảnh chuyên ngành và chuẩn hóa tuyệt đối đầu ra của mô hình.



Hình 2.1: Sơ đồ tổng quan quy trình nhận dạng thực thể y khoa

Tiền xử lý và định dạng dữ liệu (Data & Prompting): Văn bản thô từ các bộ dữ liệu y tế (ViMedNER, ViMQ) ban đầu được làm sạch và chuyển đổi thành các chuỗi chỉ dẫn (prompt) theo cấu trúc chuẩn. Quá trình này đóng vai trò định hướng ngữ cảnh quan trọng, giúp cung cấp cho mô hình ngôn ngữ lớn mục tiêu trích xuất thực thể rõ ràng cũng như định hình sẵn khuôn dạng của kết quả mong muốn.

Suy luận với mô hình Qwen2.5 (Model Inference): Các chuỗi chỉ dẫn sau khi được chuẩn bị sẽ được đưa vào mô hình nền tảng Qwen2.5-3B-Instruct. Tùy thuộc vào nguồn dữ liệu đầu vào thuộc ontology nào, hệ thống sẽ linh hoạt kích hoạt adapter LoRA tương ứng đã được tinh chỉnh riêng biệt từ trước. Tại bước này, mô hình tiến hành phân tích ngữ nghĩa phức tạp của câu và tự động sinh ra chuỗi văn bản chứa danh sách các thực thể y tế dự đoán.

Tối ưu hóa hậu xử lý (Post-processing): Do bản chất sinh văn bản tự do của kiến trúc giải mã (Decoder), chuỗi kết quả thô đầu ra thường đi kèm các ký tự dư thừa hoặc gặp hiện tượng ảo giác cấu trúc. Dữ liệu ngay lập tức được đưa qua khối hậu xử lý để tiến hành cắt tỉa các thẻ định dạng, bắt lỗi ngoại lệ trong luồng sinh từ và sàng lọc nhân. Kết quả cuối cùng được trích xuất thành cấu trúc JSON chuẩn xác, hoàn toàn tương thích với các hệ thống máy tính.

Đánh giá kết quả (Evaluation): Ở giai đoạn cuối cùng của quy trình, danh sách thực thể JSON dự đoán được bóc tách và đối chiếu trực tiếp với dữ liệu tham chiếu (Ground Truth). Hệ thống tiến hành đo lường chất lượng thông qua nhiều lăng kính kỹ thuật khác nhau, bao gồm đối khớp chính xác (Strict Match), đối khớp linh hoạt (Relaxed Match), đánh giá theo chuẩn BIO (SeqEval) và đánh giá bằng mô hình ngôn ngữ làm giám khảo (LLM-as-a-Judge) nhằm đưa ra kết luận khách quan và toàn diện nhất về năng lực của hệ thống.

2.2. Các bộ dữ liệu sử dụng trong nghiên cứu

Chất lượng và tính đặc thù của tập dữ liệu huấn luyện đóng vai trò then chốt quyết định hiệu năng của hệ thống nhận dạng thực thể, đặc biệt là đối với miền tri thức có độ phức tạp cao như y khoa. Nội dung phần này sẽ giới thiệu chi tiết về các nguồn dữ liệu tiếng Việt được lựa chọn triển khai trong nghiên cứu, đi sâu phân tích cấu trúc, đặc trưng ngữ cảnh và hệ nhãn nhằm làm rõ cơ sở thực nghiệm của đề tài.

2.2.1. Bộ dữ liệu ViMedNER

ViMedNER là bộ dữ liệu nhận dạng thực thể y khoa tiếng Việt được xây dựng nhằm hỗ trợ nghiên cứu các bài toán khai thác thông tin trong văn bản y tế. Bộ dữ liệu tập trung vào các văn bản mô tả bệnh lý, triệu chứng, nguyên nhân gây bệnh, phương pháp chẩn đoán và điều trị. Đây là một nguồn dữ liệu quan trọng cho các nghiên cứu về nhận dạng thực thể có tên trong miền y tế tiếng Việt.

Đặc điểm dữ liệu.

Khác với các bộ dữ liệu hỏi đáp y tế, ViMedNER bao gồm các câu văn mang tính mô tả, cung cấp tương đối đầy đủ ngữ cảnh liên quan đến tình trạng bệnh lý. Một câu trong bộ dữ liệu có thể chứa đồng thời nhiều thực thể thuộc các nhóm khác nhau như bệnh lý, triệu chứng, nguyên nhân hoặc phương pháp điều trị. Nhờ đó, bộ dữ liệu phản ánh khá tốt đặc trưng của các tài liệu y khoa và hồ

sơ bệnh án trong thực tế. Các mẫu dữ liệu được xây dựng dưới dạng song ngữ Việt – Anh, giúp thuận lợi cho các nghiên cứu xử lý ngôn ngữ tự nhiên đa ngôn ngữ cũng như các bài toán chuyển giao tri thức giữa các ngôn ngữ.

Hệ nhân thực thể.

ViMedNER sử dụng năm nhóm thực thể chính trong lĩnh vực y tế bao gồm: **DISEASE** (các bệnh lý hoặc tình trạng bệnh), **SYMPTOM** (các triệu chứng hoặc biểu hiện lâm sàng của bệnh), **CAUSE** (nguyên nhân hoặc yếu tố gây bệnh), **DIAGNOSTIC** (các phương pháp chẩn đoán, xét nghiệm hoặc kỹ thuật hỗ trợ chẩn đoán) và **TREATMENT** (các phương pháp điều trị hoặc can thiệp y khoa). Hệ nhân này cho phép mô hình không chỉ nhận diện bệnh lý mà còn khai thác được các thông tin liên quan trong quá trình chẩn đoán và điều trị, từ đó hỗ trợ hiệu quả cho các ứng dụng phân tích văn bản y tế.

Cấu trúc dữ liệu.

```
{
  "vi_sentence_str": "Viêm mũi dị ứng có thể cản trở sự thú vị của các hoạt động và làm cho bị giảm năng suất .",
  "en_sentence_str": "Allergic rhinitis can interfere with the enjoyment of activities and cause reduced productivity .",
  "entities": [
    {
      "label": "DISEASE",
      "vi_term": "viêm mũi dị ứng",
      "vi_start_token_idx": 0,
      "vi_end_token_idx": 3,
      "en_term": "Allergic rhinitis",
      "en_start_token_idx": 0,
      "en_end_token_idx": 1
    }
  ]
}
```

Hình 2.2: Mô tả cấu trúc một mẫu dữ liệu của bộ ViMedNER

Hình 2.2 minh họa cấu trúc của một mẫu dữ liệu trong bộ ViMedNER. Mỗi mẫu được lưu trữ dưới dạng một đối tượng JSON, bao gồm hai trường văn bản là `vi_text` và `en_text`, tương ứng với nội dung tiếng Việt và tiếng Anh của cùng một câu.

Danh sách các thực thể được lưu trữ trong trường `entities`. Mỗi thực thể bao gồm các thuộc tính quan trọng: nội dung thực thể (`term`), loại thực thể (`label`), cùng với vị trí xuất hiện trong câu thông qua chỉ số bắt đầu (`start_idx`) và chỉ số kết thúc (`end_idx`). Các thông tin này cho phép xác định chính xác ranh giới cũng như phân loại của từng thực thể trong văn bản.

Trong ví dụ ở Hình 2.2, câu văn mô tả một bệnh nhân viêm phổi, trong đó cụm từ "viêm phổi" được gán nhãn DISEASE; các triệu chứng như "ho", "sốt" và "khó thở" được gán nhãn SYMPTOM; và phương pháp điều trị bằng kháng sinh được gán nhãn TREATMENT. Qua ví dụ này, có thể thấy một câu đơn lẻ có thể chứa nhiều loại thực thể khác nhau, phản ánh tính phức tạp của bài toán trích xuất thực thể (NER) trong lĩnh vực y tế. Nhờ cấu trúc chú thích chi tiết cùng hệ thống nhân đa dạng, ViMedNER là bộ dữ liệu phù hợp để đánh giá khả năng nhận diện thực thể y khoa của các mô hình ngôn ngữ lớn trong môi trường tiếng Việt.

2.2.2. Bộ dữ liệu ViMQ

ViMQ là bộ dữ liệu nhận dạng thực thể y khoa tiếng Việt được xây dựng trên miền dữ liệu hỏi đáp sức khỏe. Khác với ViMedNER tập trung vào các văn bản mô tả bệnh lý, ViMQ bao gồm các câu hỏi y khoa được thu thập từ nhu cầu tra cứu và tư vấn sức khỏe của người dùng. Bộ dữ liệu được xây dựng nhằm hỗ trợ nghiên cứu các hệ thống xử lý ngôn ngữ tự nhiên trong lĩnh vực y tế, đặc biệt là các bài toán nhận dạng thực thể và khai thác thông tin từ câu hỏi y khoa.

Đặc điểm dữ liệu.

Các mẫu dữ liệu trong ViMQ chủ yếu được biểu diễn dưới dạng câu hỏi liên quan đến bệnh lý, triệu chứng, thuốc hoặc các thủ thuật y khoa. So với dữ liệu mô tả bệnh lý, các câu trong ViMQ thường ngắn gọn hơn, tập trung trực tiếp vào vấn đề mà người dùng quan tâm và chứa ít ngữ cảnh hỗ trợ hơn. Đặc điểm này khiến bài toán nhận dạng thực thể trở nên thách thức hơn do mô hình phải suy luận loại thực thể từ lượng thông tin hạn chế. Đồng thời, cách diễn đạt trong câu hỏi của người dùng thường đa dạng và ít mang tính chuẩn hóa hơn so với các tài liệu y khoa chuyên ngành.

Hệ nhãn thực thể.

ViMQ sử dụng ba nhóm thực thể chính bao gồm: SYMPTOM_AND_DISEASE (các bệnh lý, triệu chứng hoặc biểu hiện liên quan đến sức khỏe), MEDICAL_PROCEDURE (các thủ thuật y khoa, phương pháp chẩn đoán hoặc can thiệp điều trị), và DRUG (các loại thuốc, hoạt chất hoặc sản phẩm dược phẩm được đề cập trong câu hỏi). So với ViMedNER, hệ nhãn của ViMQ được thiết kế gọn hơn nhằm phù hợp với đặc điểm của dữ liệu hỏi đáp. Đặc biệt, nhóm bệnh lý và triệu chứng được gộp chung thành nhãn SYMPTOM_AND_DISEASE do trong nhiều trường hợp người dùng thường mô tả tình trạng sức khỏe mà không phân biệt rõ giữa triệu chứng và tên bệnh.

Cấu trúc dữ liệu.

```
{
  "vi_sentence_str": "Bé gần 4 tháng không biết khóc đòi bế , đôi chỉ mút tay , ít hóng chuyện có làm sao không ?",
  "en_sentence_str": "Is it a problem if a nearly 4-month-old baby does not cry to be held , just sucks their hands v",
  "entities": [
    {
      "label": "SYMPTOM_AND_DISEASE",
      "vi_term": "khóc đòi bế",
      "vi_start_token_idx": 6,
      "vi_end_token_idx": 8,
      "en_term": "cry to be held",
      "en_start_token_idx": 11,
      "en_end_token_idx": 14,
    },
    {
      "label": "SYMPTOM_AND_DISEASE",
      "vi_term": "đôi chỉ mút tay",
      "vi_start_token_idx": 10,
      "vi_end_token_idx": 13,
      "en_term": "sucks their hands when hungry",
      "en_start_token_idx": 17,
      "en_end_token_idx": 21,
    },
    {
      "label": "SYMPTOM_AND_DISEASE",
      "vi_term": "ít hóng chuyện",
      "vi_start_token_idx": 15,
      "vi_end_token_idx": 17,
      "en_term": "lack of social interaction",
      "en_start_token_idx": 26,
      "en_end_token_idx": 29
    }
  ]
}
```

Hình 2.3: Ví dụ một mẫu dữ liệu trong bộ dữ liệu ViMQ

Tương tự ViMedNER, mỗi mẫu dữ liệu trong ViMQ được lưu trữ dưới dạng một đối tượng JSON. Như minh họa trong Hình 2.3, mỗi mẫu bao gồm hai trường văn bản là `vi_text` và `en_text`, tương ứng với nội dung câu hỏi bằng tiếng Việt và tiếng Anh.

Các thực thể được lưu trong trường `entities`. Mỗi thực thể bao gồm nội dung thực thể (`term`), loại thực thể (`label`) cùng vị trí xuất hiện trong câu thông qua chỉ số bắt đầu (`start_idx`) và chỉ số kết thúc (`end_idx`). Cách biểu diễn này cho phép xác định chính xác ranh giới của từng thực thể và thuận lợi cho việc đánh giá chất lượng dự đoán của mô hình. Hình 2.3 minh họa một mẫu dữ liệu trong ViMQ, cho thấy câu hỏi đầu vào thường chứa số lượng thực thể không nhiều nhưng các thực thể lại mang thông tin trọng tâm của câu hỏi. Điều này phản ánh đúng đặc trưng của dữ liệu hỏi đáp y tế, nơi người dùng thường tập trung vào một vấn đề sức khỏe cụ thể cần được giải đáp.

2.2.3. So sánh hai bộ dữ liệu

Để làm nổi bật sự khác biệt về đặc trưng văn bản và định hướng ứng dụng, Bảng 2.1 trình bày tổng hợp các tiêu chí so sánh giữa bộ dữ liệu ViMedNER và ViMQ.

Tiêu chí	ViMedNER	ViMQ
Loại dữ liệu	Văn bản mô tả bệnh lý, triệu chứng, chẩn đoán và điều trị	Câu hỏi y khoa và tư vấn sức khỏe
Miền ứng dụng	Tài liệu y khoa, hồ sơ bệnh án, mô tả bệnh lý	Hệ thống hỏi đáp, tra cứu thông tin sức khỏe
Kiểu câu văn	Câu dài, nhiều ngữ cảnh, mang tính mô tả	Câu hỏi ngắn gọn, trực tiếp, ít ngữ cảnh
Mật độ thực thể	Nhiều thực thể trong cùng một câu	Thực thể ít, tập trung vào nội dung chính
Độ phức tạp ngữ cảnh	Ngữ cảnh đầy đủ, thực thể liên kết rõ ràng	Ngữ cảnh hạn chế, đòi hỏi suy luận
Số lượng nhãn	5 nhãn thực thể	3 nhãn thực thể
Các nhãn thực thể	DISEASE, SYMPTOM, CAUSE, DIAGNOSTIC, TREATMENT	SYMPTOM_AND_DISEASE, MEDICAL_PROCEDURE, DRUG
Mục tiêu khai thác	Nhận diện thông tin bệnh lý, điều trị	Nhận diện thực thể trong câu hỏi y khoa
Thách thức chính	Nhận diện thực thể trong văn bản dài	Nhận diện đúng khi thông tin hạn chế

Bảng 2.1: So sánh hai bộ dữ liệu ViMedNER và ViMQ

2.3. Lựa chọn mô hình và chiến lược tinh chỉnh

Để xử lý hiệu quả hai bộ dữ liệu mang đặc thù khác biệt rõ rệt như ViMedNER và ViMQ, việc lựa chọn một kiến trúc mô hình nền tảng phù hợp và thiết kế chiến lược huấn luyện tối ưu là yếu tố mang tính quyết định. Sự khác biệt về cấu trúc văn bản (mô tả bệnh lý so với câu hỏi trực tiếp) và sự không đồng nhất trong hệ nhãn (ontology) đặt ra thách thức lớn đối với việc tích hợp tất cả vào một mô hình duy nhất. Do đó, nội dung phần này sẽ trình bày chi tiết về việc lựa chọn mô hình ngôn ngữ Qwen2.5-3B-Instruct làm lõi suy luận, đồng thời phân tích chiến lược tinh chỉnh linh hoạt thông qua việc huấn luyện các adapter độc lập. Hướng tiếp cận này không chỉ giải quyết triệt để vấn đề xung đột không gian nhãn mà còn tối ưu hóa hiệu năng khi triển khai trên các hệ thống có giới hạn về tài nguyên tính toán.

2.3.1. Mô hình Qwen2.5-3B-Instruct

Qwen2.5-3B-Instruct là dòng mô hình ngôn ngữ lớn thế hệ mới do Alibaba Cloud phát triển, đóng vai trò là lõi xử lý trung tâm trong nghiên cứu này. Được xây dựng trên kiến trúc Transformer Decoder tự hồi quy (autoregressive), mô hình học cách dự đoán token tiếp theo dựa trên toàn bộ ngữ cảnh phía trước, từ đó thiết lập được các mối quan hệ ngữ nghĩa phức tạp và xử lý hiệu quả các chuỗi văn bản dài trong lĩnh vực y tế. Điểm đặc thù của dòng Instruct là đã trải qua giai đoạn tinh chỉnh theo chỉ dẫn (instruction tuning), giúp mô hình không chỉ hiểu các quy luật ngôn ngữ thô mà còn có khả năng thực hiện chính xác các yêu cầu được mô tả bằng ngôn ngữ tự nhiên.

Khả năng đa ngôn ngữ mạnh mẽ là một trong những lý do then chốt dẫn đến việc lựa chọn Qwen2.5. Nhờ được huấn luyện trên tập dữ liệu khổng lồ bao phủ nhiều ngôn ngữ, bao gồm cả tiếng Việt, mô hình sở hữu sự nhạy bén đối với các biến thể ngữ pháp và cách diễn đạt chuyên ngành y khoa tại Việt Nam. Trong bài toán nhận dạng thực thể có tên, thay vì sử dụng các phương pháp phân loại token truyền thống vốn đòi hỏi việc thiết kế lại lớp đầu ra, Qwen2.5 cho phép triển khai theo hướng Generative NER. Theo đó, mô hình nhận một câu văn đầu vào và sinh trực tiếp danh sách thực thể dưới dạng văn bản có cấu trúc, giúp tận dụng tối đa khả năng suy luận và tri thức nội tại của một mô hình ngôn ngữ lớn. Việc lựa chọn phiên bản 3B (3 tỷ tham số) giúp nghiên cứu đạt được sự cân bằng tối ưu giữa năng lực xử lý ngôn ngữ và yêu cầu về tài nguyên phần cứng, đảm bảo hệ thống vận hành ổn định trên các nền tảng điện toán đám mây phổ thông.

2.3.2. Chiến lược huấn luyện các Adapter LoRA độc lập

Thay vì tích hợp tất cả các bộ dữ liệu vào một mô hình duy nhất, nghiên cứu đề xuất chiến lược huấn luyện các adapter LoRA độc lập cho từng ontology (ViMedNER và ViMQ). Quyết định này xuất phát từ việc hai bộ dữ liệu có hệ

thống nhân thực thể khác nhau và đặc thù văn bản riêng biệt; việc gộp chung có thể dẫn đến hiện tượng nhiễu loạn thông tin hoặc xung đột định nghĩa thực thể trong quá trình hội tụ của mô hình. Bằng cách sử dụng kỹ thuật Low-Rank Adaptation (LoRA), hệ thống chỉ tiến hành cập nhật một lượng nhỏ các ma trận hỗ trợ trong khi giữ nguyên toàn bộ trọng số của mô hình gốc Qwen2.5. Điều này giúp mỗi adapter tập trung học sâu vào các đặc trưng chuyên biệt của từng bộ dữ liệu, đồng thời giảm thiểu đáng kể chi phí lưu trữ và tính toán.

Để giải quyết bài toán vận hành trên môi trường Google Colab với giới hạn về bộ nhớ VRAM, nghiên cứu kết hợp kỹ thuật LoRA với lượng tử hóa 4-bit. Kỹ thuật này cho phép nén trọng số mô hình xuống mức thấp mà vẫn duy trì được độ chính xác cần thiết, giúp quy trình huấn luyện không gây quá tải bộ nhớ trên các GPU phổ thông như NVIDIA T4. Bên cạnh đó, việc sử dụng thư viện Unsloth giúp tối ưu hóa quá trình tính toán gradient và quản lý bộ nhớ đệm, đẩy nhanh tốc độ huấn luyện gấp nhiều lần so với các phương pháp thông thường. Chiến lược này đảm bảo tính khả thi tuyệt đối của đề tài: mô hình có thể được huấn luyện nhanh chóng, dễ dàng chuyển đổi qua lại giữa các ontology khác nhau thông qua việc thay thế adapter, đồng thời mở ra khả năng mở rộng hệ thống cho các bộ dữ liệu y tế mới trong tương lai mà không cần huấn luyện lại từ đầu mô hình nền tảng.

2.4. Tối ưu hóa hậu xử lý dữ liệu

Đặc thù của các mô hình ngôn ngữ lớn dựa trên kiến trúc giải mã là bản chất sinh văn bản tự do. Bất chấp việc áp dụng các kỹ thuật tinh chỉnh và prompt kiểm soát chặt chẽ, mô hình đôi khi vẫn kế thừa tàn dư của quá trình học hội thoại, dẫn đến việc sinh ra các chuỗi ký tự phụ trợ hoặc định dạng không mong muốn. Do bài toán nhận dạng thực thể y tế đòi hỏi độ chính xác tuyệt đối về mặt cấu trúc và tọa độ không gian văn bản, quá trình hậu xử lý là bước bắt buộc để chuẩn hóa kết quả thô về định dạng máy tính có thể đánh giá nghiêm ngặt.

Bộ lọc khử ảo giác thực thể và làm sạch cấu trúc

Mặc dù tham số giải mã tham lam đã được kích hoạt nhằm hạn chế tính ngẫu nhiên, hệ thống đôi khi vẫn gặp phải hiện tượng ảo giác cấu trúc. Trong các trường hợp này, mô hình có xu hướng sinh thêm các lời dẫn hội thoại phụ trợ hoặc bọc kết quả bên trong các thẻ định dạng Markdown. Để trích xuất chính xác cấu trúc dữ liệu đích, một thuật toán lọc đa tầng đã được nghiên cứu và triển khai.

Bước đầu tiên trong quy trình là cắt tỉa thẻ định dạng định hướng, trong đó hệ thống sử dụng các biểu thức chính quy (regular expressions) để tự động dò tìm và loại bỏ các khối thẻ đánh dấu ngôn ngữ, chỉ giữ lại phần nội dung mang cấu trúc ngoặc nhọn đặc trưng của định dạng JSON. Tiếp theo, khối dữ liệu sau khi cắt tỉa được đưa qua cơ chế bắt lỗi ngoại lệ thông qua bộ phân tích cú pháp

`json.loads()`. Các khối `try-except` được thiết lập chặt chẽ nhằm xử lý các trường hợp chuỗi văn bản bị đứt gãy do quá trình sinh chậm ngưỡng độ dài tối đa (`max_new_tokens`). Thay vì gây lỗi và làm sập toàn bộ tiến trình hệ thống, những dự đoán hỏng này sẽ được bộ lọc xử lý mềm mỏng và ghi nhận dưới dạng một mảng rỗng.

Cuối cùng, hệ thống thực hiện sàng lọc schema y tế mục tiêu bằng cách kiểm tra phân loại của từng thực thể trích xuất được. Bất kỳ thực thể nào chứa thuộc tính `label` không nằm trong danh sách nhãn mục tiêu chuẩn hóa của ontology đều bị bộ lọc tự động loại bỏ. Thuật toán đa tầng này đảm bảo đầu ra cuối cùng hoàn toàn sạch sẽ, có cấu trúc chuẩn xác và sẵn sàng cho các bước đối khớp tự động trong quá trình đánh giá.

2.5. Các phương pháp đánh giá mô hình

Do bản chất sinh văn bản của hệ thống sử dụng mô hình ngôn ngữ lớn, việc đánh giá chất lượng nhận dạng thực thể không thể chỉ dựa vào một thước đo duy nhất. Để phản ánh chính xác và toàn diện năng lực của hệ thống, quá trình đánh giá cần được thực hiện qua nhiều lăng kính khác nhau. Nội dung phần này trình bày chi tiết các phương pháp đo lường được áp dụng trong nghiên cứu, trải dài từ các tiêu chuẩn đối khớp khắt khe về mặt ranh giới ký tự và định dạng (như Strict Match và chuẩn BIO tagging) đến các tiêu chí linh hoạt hơn về mặt không gian chồng lấp (Relaxed Match). Đặc biệt, hệ thống còn tích hợp phương pháp đánh giá sâu về mặt ngữ nghĩa chuyên ngành thông qua việc sử dụng một mô hình ngôn ngữ lớn độc lập làm giám khảo (LLM-as-a-Judge), từ đó tạo ra một khung đối chiếu đa chiều, khách quan và bám sát thực tiễn bài toán.

2.5.1. Đánh giá NER dựa trên span thực thể

Trong bài toán nhận dạng thực thể có tên, mỗi thực thể thường được biểu diễn dưới dạng một span gồm vị trí bắt đầu, vị trí kết thúc và nhãn thực thể tương ứng. Việc đánh giá mô hình dựa trên span thực thể tập trung vào việc so sánh các thực thể dự đoán với dữ liệu tham chiếu để xác định mức độ chính xác của kết quả nhận dạng. Khác với các bài toán phân loại thông thường, một thực thể được xem là đúng không chỉ khi dự đoán đúng loại thực thể mà còn phải xác định đúng ranh giới xuất hiện của thực thể trong văn bản. Trong nghiên cứu này, hai phương pháp được sử dụng là Strict Match và Relaxed Match.

Phương pháp Strict Match, hay Exact Match, là tiêu chí đánh giá nghiêm ngặt nhất. Một thực thể dự đoán chỉ được xem là đúng khi đồng thời thỏa mãn hai điều kiện: span thực thể phải khớp hoàn toàn với thực thể tham chiếu và nhãn thực thể phải trùng khớp với nhãn tham chiếu. Giả sử thực thể tham chiếu được biểu diễn dưới dạng $(start_G, end_G, label_G)$ và thực thể dự đoán là $(start_P, end_P, label_P)$, thì một dự đoán được tính là đúng khi và chỉ khi $start_P = start_G$, $end_P = end_G$ và $label_P = label_G$. Bất kỳ sự sai khác nào trong ba thành

phần này đều khiến thực thể bị xem là dự đoán sai. Mặc dù phản ánh chính xác khả năng nhận diện đầy đủ, tiêu chí này đôi khi quá khắt khe đối với các mô hình sinh văn bản, bởi mô hình có thể xác định đúng thực thể nhưng lệch nhẹ về ranh giới span.

Để khắc phục hạn chế này, phương pháp Relaxed Match được áp dụng nhằm đánh giá mức độ tương đồng. Thay vì yêu cầu span phải khớp tuyệt đối, Relaxed Match cho phép thực thể dự đoán và thực thể tham chiếu được xem là khớp nếu chúng có mức độ chồng lấp đủ lớn và cùng nhãn thực thể. Mức độ chồng lấp được xác định thông qua chỉ số Intersection over Union (IoU), tính bằng tỷ lệ giữa độ dài phần giao và độ dài phần hợp của hai span.

$$IoU = \frac{|P \cap G|}{|P \cup G|}$$

Trong đó P là span thực thể dự đoán, G là span thực thể tham chiếu, $|P \cap G|$ là độ dài phần giao và $|P \cup G|$ là độ dài phần hợp. Trong nghiên cứu này, một thực thể dự đoán được xem là khớp một phần với thực thể tham chiếu khi giá trị IoU lớn hơn hoặc bằng 0.5 và nhãn thực thể của hai span giống nhau. Ngưỡng này đảm bảo phần lớn nội dung của thực thể đã được mô hình nhận diện chính xác, phản ánh tốt hơn mức độ hiểu ngữ nghĩa của hệ thống và bổ sung cho thước đo Strict Match.

2.5.2. Đánh giá theo chuẩn BIO tagging với SeqEval

Bên cạnh các phương pháp đánh giá dựa trên span thực thể, nghiên cứu còn sử dụng thư viện SeqEval để đánh giá mô hình theo chuẩn NER truyền thống. Đây là phương pháp phổ biến trong các bộ dữ liệu định dạng CoNLL. Chuẩn BIO tagging là phương pháp biểu diễn thực thể dưới dạng chuỗi nhãn gán cho từng token trong câu. Cụ thể, nhãn B biểu thị token đầu tiên của một thực thể, nhãn I biểu thị các token nằm bên trong cùng thực thể, và nhãn O biểu thị token không thuộc bất kỳ thực thể nào. Thông qua biểu diễn này, bài toán nhận dạng thực thể được chuyển thành bài toán gán nhãn chuỗi.

Nhiều bộ dữ liệu NER truyền thống được lưu trữ dưới định dạng CoNLL, trong đó mỗi dòng tương ứng với một token và nhãn BIO đi kèm. SeqEval là thư viện đánh giá chuyên dụng hỗ trợ tính toán các chỉ số hiệu năng dựa trên chuỗi nhãn BIO theo tiêu chuẩn này. Khác với việc đánh giá ở mức token riêng lẻ, SeqEval thực hiện đánh giá ở cấp độ thực thể, nghĩa là một thực thể chỉ được xem là dự đoán đúng khi cả ranh giới và nhãn đều khớp với dữ liệu tham chiếu. Dựa trên nguyên tắc đó, các chỉ số cốt lõi được SeqEval tính toán thông qua hệ phương trình sau:

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F_1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Trong đó, các biến số thống kê được xác định một cách nghiêm ngặt ở cấp độ toàn vẹn của thực thể. Đại lượng *TP* (True Positive) là số lượng thực thể dự đoán hoàn toàn trùng khớp với thực thể tham chiếu về cả chuỗi token và nhãn BIO. Đại lượng *FP* (False Positive) đại diện cho các thực thể do mô hình sinh ra nhưng không tồn tại trong dữ liệu chuẩn hoặc có sự sai lệch một phần. Cuối cùng, đại lượng *FN* (False Negative) phản ánh số lượng thực thể thực tế có trong văn bản nhưng bị mô hình bỏ sót hoặc gán nhãn sai.

Trong nghiên cứu này, kết quả dự đoán của mô hình được chuyển đổi từ dạng span sang chuỗi nhãn BIO trước khi đưa vào SeqEval để tính toán. Ưu điểm của phương pháp này là tuân thủ hệ quy chiếu phổ biến, kết hợp cùng các công thức đo lường chuẩn xác, giúp kết quả đánh giá có độ tin cậy cao và dễ dàng so sánh chéo với các công trình nghiên cứu trước đây.

2.5.3. Đánh giá bằng mô hình ngôn ngữ lớn làm giám khảo (LLM-as-a-Judge)

Các phương pháp đánh giá truyền thống như Strict Match, Relaxed Match hay SeqEval chủ yếu dựa trên việc đối sánh ký tự hoặc ranh giới. Mặc dù mang tính khách quan và dễ tái lập, chúng chưa phản ánh đầy đủ mức độ tương đồng về mặt ngữ nghĩa chuyên ngành. Đối với các mô hình ngôn ngữ lớn, kết quả dự đoán đôi khi có thể khác biệt một phần về cách biểu diễn từ vựng hoặc bị thừa thiếu một vài từ phụ trợ nhưng vẫn chính xác về ý nghĩa y khoa. Trong những trường hợp như vậy, các phương pháp truyền thống thường đánh giá là sai hoàn toàn.

Để giải quyết vấn đề này, nghiên cứu tích hợp phương pháp dùng mô hình ngôn ngữ lớn làm giám khảo. Theo đó, một mô hình độc lập đóng vai trò giám khảo sẽ nhận đầu vào gồm văn bản gốc, danh sách thực thể tham chiếu và danh sách thực thể dự đoán. Mô hình này tiến hành phân tích và đối sánh dựa trên cả thông tin cú pháp lẫn ngữ nghĩa. Phương pháp này mang lại ưu điểm vượt trội trong việc đánh giá linh hoạt, phân loại chi tiết các dạng lỗi sinh văn bản và đặc biệt phù hợp với các hệ thống Generative NER. Mặc dù làm gia tăng chi phí tính toán và phụ thuộc vào năng lực suy luận của mô hình giám khảo, phương pháp này vẫn là một công cụ đắc lực hỗ trợ phân tích kết quả thực nghiệm sâu sắc hơn, mang lại góc nhìn đa chiều về chất lượng thực tế của hệ thống.

2.6. Tổng kết chương

Chương này đã trình bày một cách hệ thống và toàn diện về hướng tiếp cận cũng như kiến trúc tổng thể được đề xuất để giải quyết bài toán nhận dạng thực thể y tế tiếng Việt. Quá trình nghiên cứu bắt đầu từ việc phân tích sâu sắc đặc trưng của hai bộ dữ liệu ViMedNER và ViMQ, từ đó làm cơ sở cho việc lựa

chọn mô hình nền tảng Qwen2.5-3B-Instruct. Thay vì sử dụng một mô hình duy nhất, chiến lược huấn luyện các adapter LoRA độc lập đã được áp dụng nhằm tối ưu hóa hiệu năng tính toán trên môi trường phần cứng giới hạn và giải quyết triệt để vấn đề xung đột không gian nhớ giữa các ontology khác nhau.

Bên cạnh đó, để khắc phục bản chất sinh văn bản tự do của kiến trúc giải mã, một bộ lọc hậu xử lý đa tầng đã được thiết kế nhằm chuẩn hóa tuyệt đối dữ liệu đầu ra về định dạng cấu trúc. Các phương pháp đánh giá đa chiều, trải dài từ đối khớp span thực thể, chuẩn BIO tagging đến việc sử dụng mô hình ngôn ngữ lớn làm giám khảo cũng được thiết lập một cách chặt chẽ. Toàn bộ quy trình từ khâu chuẩn bị dữ liệu, tinh chỉnh mô hình đến hậu xử lý đã được liên kết thành một đường ống hệ thống hoàn chỉnh. Đây chính là tiền đề kỹ thuật vững chắc để hệ thống bước vào quá trình triển khai thực nghiệm, đo lường và phân tích kết quả chuyên sâu sẽ được trình bày chi tiết trong chương tiếp theo.

Chương 3

Thực nghiệm bài toán

Chương này trình bày chi tiết toàn bộ quy trình thực tiễn được triển khai để giải quyết bài toán nhận dạng thực thể y tế. Nội dung chương bao quát từ bước thiết lập môi trường tính toán, cấu hình các siêu tham số huấn luyện mô hình ngôn ngữ bằng kỹ thuật QLoRA, cho đến quy trình suy luận, hậu xử lý và xây dựng khung đánh giá đa phương pháp. Mục tiêu của chương là cung cấp các minh chứng định lượng rõ ràng, đảm bảo tính minh bạch và khả năng tái lập cao cho hệ thống đã đề xuất.

3.1. Cài đặt môi trường và công cụ thực nghiệm

Để vận hành trơn tru các mô hình ngôn ngữ lớn có hàng tỷ tham số, việc chuẩn hóa cơ sở hạ tầng tính toán là điều kiện tiên quyết. Mục này mô tả chi tiết nền tảng phần cứng đám mây được sử dụng, cũng như danh sách các thư viện mã nguồn mở cốt lõi đóng vai trò khung xương cho toàn bộ vòng đời phát triển của mô hình.

3.1.1. Môi trường phần mềm và thư viện cốt lõi

Hệ thống được phát triển chủ yếu bằng ngôn ngữ lập trình Python, vận hành thông qua môi trường tương tác Jupyter Notebook trên nền tảng hệ điều hành Linux. Việc triển khai các mô hình ngôn ngữ lớn đòi hỏi sự phối hợp chặt chẽ của nhiều thư viện chuyên dụng, được chia thành các nhóm sinh thái cốt lõi nhằm tối ưu hóa từng giai đoạn từ xử lý dữ liệu đến tinh chỉnh trọng số.

3.1.1.1. Hệ sinh thái mã nguồn mở Hugging Face:

- **transformers**: Thư viện cốt lõi cung cấp cấu trúc lập trình điều khiển mô hình và bộ phân tách mã báo. Thư viện này hỗ trợ nạp cấu hình tự động, quản lý cơ chế sinh chuỗi tự động và tối ưu hóa từ vựng y tế cho mô hình Qwen2.5-7B-Instruct cùng các mô hình liên quan.
- **peft**: Thư viện chuyên dụng để triển khai giải thuật LoRA. Thư viện đóng vai trò bọc mô hình nền, đóng băng các tham số gốc và phân tách việc huấn luyện vào các ma trận hạng thấp bổ trợ, giúp giảm thiểu hơn 90% số lượng tham số cần cập nhật mà không làm suy giảm năng lực biểu diễn ngữ nghĩa của mô hình.

- **bitsandbytes**: Công cụ lượng hóa toán học cao cấp. Thư viện này chịu trách nhiệm biến đổi các trọng số có độ chính xác đơn lẻ hoặc độ chính xác một nửa của mô hình nền về định dạng 4-bit NF4. Đây là điều kiện tiên quyết để vận hành các mô hình có kích thước tham số lớn trên phần cứng giới hạn đồ họa như GPU T4.
- **datasets**: Cấu phần tối ưu hóa luồng dữ liệu, hỗ trợ tải, xử lý sơ bộ, phân tách phân đoạn dữ liệu và ánh xạ dữ liệu đầu vào thành các tensor số hóa một cách nhanh chóng, tiết kiệm tài nguyên bộ nhớ hệ thống.

3.1.1.2. Thư viện kiểm định hệ thống và hỗ trợ tính toán:

- **segeval**: Thư viện đánh giá chuẩn hóa cấp độ chuỗi. Trong bài toán NER, **segeval** áp dụng các thuật toán so khớp khớp khe dựa trên hệ thống thẻ BIO, tính toán chính xác các chỉ số *Strict Precision*, *Strict Recall* và *Strict F1-Score* theo tiêu chuẩn của các hội nghị quốc tế CoNLL.
- **torch**: Khung lập trình học sâu nền tảng, điều phối và phân bổ toàn bộ tài nguyên tính toán ma trận ma sát, quản lý luồng dữ liệu truyền lên GPU thông qua cấu hình lệnh tự động `device_map="auto"`.
- **tqdm**: Thư viện hỗ trợ xây dựng thanh tiến trình thời gian thực, cho phép theo dõi sát sao tốc độ huấn luyện trên từng phân đoạn vòng lặp và đo lường thời gian suy luận trên hàng ngàn câu văn bản kiểm thử.

3.2. Huấn luyện mô hình với kỹ thuật Quantized LoRA

Giai đoạn này trình bày chi tiết các thông số thực nghiệm thu được từ quá trình tinh chỉnh mô hình **Qwen/Qwen2.5-3B-Instruct** thông qua kỹ thuật QLoRA. Các số liệu được trích xuất trực tiếp từ nhật ký hệ thống nhằm minh chứng cho tính hiệu quả của phương pháp huấn luyện.

3.2.1. Chi phí tham số và Cấu hình lượng hóa

Thông qua kỹ thuật nén 4-bit kết hợp với LoRA, hệ thống đã đóng băng toàn bộ mạng lưới gốc và chỉ khởi tạo các ma trận phụ trợ. Kết quả thống kê từ hệ thống cho thấy:

- **Tổng số tham số**: 3,115,872,256.
- **Tham số được huấn luyện**: 29,933,568.
- **Tỷ lệ huấn luyện**: Đạt 0.9607%.

Con số này minh chứng cho sức mạnh tuyệt đối của QLoRA. Thay vì phải cập nhật và lưu trữ gradient cho 3.1 tỷ tham số, hệ thống chỉ tập trung tối ưu hóa xấp xỉ 29.9 triệu tham số. Khi kết thúc quá trình, tệp trọng số Adapter xuất ra chỉ chiếm **426.59 MB**, vô cùng nhỏ gọn, cho phép triển khai và tải trực tiếp lên các hệ thống phần cứng giới hạn mà không gặp trở ngại.

3.2.2. Quy mô dữ liệu và Khởi tạo ngữ cảnh

Quá trình sàng lọc dữ liệu thô và token hóa với `max_length = 384` đã loại bỏ các câu bất thường, cung cấp tập dữ liệu sạch đưa vào đồ thị tính toán:

- **Tập ViMedNER:** Gồm 4,576 câu huấn luyện và 1,524 câu kiểm định.
- **Tập ViMQ:** Gồm 6,994 câu huấn luyện và 999 câu kiểm định.

3.2.3. Giám sát quá trình hội tụ và Tối ưu hóa thuật toán

Tiến trình huấn luyện được thực thi trong **1.0 epoch**. Nhật ký huấn luyện trên tập ViMQ cung cấp các chỉ báo toán học quan trọng:

- **Hàm mất mát:** Bắt đầu từ chu kỳ 0.69, `loss` đạt mức 0.04041 và tiếp tục suy giảm ổn định xuống mức 0.02887 ở cuối chu kỳ. Đặc biệt, hàm mất mát trên tập kiểm định chốt ở mức 0.04567. Khoảng cách cực kỳ nhỏ giữa `train_loss` và `eval_loss` là tín hiệu vàng trong học máy, chứng minh mô hình đã học được tổng quát hóa tốt ngữ nghĩa y khoa thay vì học vẹt (*overfitting*) dữ liệu huấn luyện.
- **Biến thiên tốc độ học:** Tốc độ học được quan sát giảm dần đều từ 6.274×10^{-5} xuống mức 1.415×10^{-6} ở những bước cuối. Đây là minh chứng hệ thống đã áp dụng thành công chiến lược giảm cấp *Cosine Learning Rate Scheduler*. Việc tốc độ học nhỏ dần ở cuối chu kỳ giúp trọng số mô hình "hạ cánh" mượt mà vào điểm cực tiểu của hàm mất mát, tránh hiện tượng trượt khỏi điểm tối ưu.
- **Độ chuẩn Gradient:** Dao động trong khoảng an toàn từ 0.8393 giảm dần xuống 0.2655. `grad_norm` phản ánh mức độ "rung lắc" của đồ thị tính toán đạo hàm. Các giá trị này đều ≤ 1.0 chứng tỏ thuật toán tối ưu `paged_adamw_8bit` đã hoạt động hoàn hảo, chặn đứng hoàn toàn rủi ro bùng nổ đạo hàm - một lỗi rất hay gặp khi fine-tune LLM.

3.2.4. Hiệu năng phần cứng và Tính bền bỉ của hệ thống

Quá trình huấn luyện không diễn ra liên tục 100% mà bị chi phối bởi giới hạn thời gian thực thi của môi trường Kaggle. Tuy nhiên, hệ thống đã ghi nhận việc xử lý thành công ngoại lệ này:

```

6429.8s 85 {'loss': '0.04191', 'grad_norm': '0.3329', 'learning_rate': '1.321e-05', 'epoch': '0.9379'}
6672.2s 86 {'loss': '0.03323', 'grad_norm': '0.3031', 'learning_rate': '1.085e-05', 'epoch': '0.9494'}
6914.9s 87 {'loss': '0.03916', 'grad_norm': '0.3109', 'learning_rate': '8.491e-06', 'epoch': '0.9608'}
7157.5s 88 {'loss': '0.04487', 'grad_norm': '0.2664', 'learning_rate': '6.132e-06', 'epoch': '0.9723'}
7401.9s 89 {'loss': '0.0386', 'grad_norm': '0.3684', 'learning_rate': '3.774e-06', 'epoch': '0.9837'}
7646.2s 90 {'loss': '0.02887', 'grad_norm': '0.2655', 'learning_rate': '1.415e-06', 'epoch': '0.9951'}
8737.8s 91 {'eval_loss': '0.04567', 'eval_runtime': '985.2', 'eval_samples_per_second': '1.014',
'eval_steps_per_second': '1.014', 'epoch': '1'}
8738.7s 92 {'train_runtime': '8633', 'train_samples_per_second': '0.81', 'train_steps_per_second': '0.101',
'train_loss': '0.01364', 'epoch': '1'}
8738.7s 93 [vimq] 5/5 Saving final model & metadata...
8739.5s 94 [vimq] Done. Saved to: /kaggle/working/ner_adapters/qwen2p5_3b_vimq_ner_lora

```

Hình 3.1: Biểu đồ suy giảm hàm mất mát và biến thiên tốc độ học trong quá trình huấn luyện QLoRA

- **Cơ chế Resume Checkpoint:** Nhật ký hệ thống ghi nhận dòng lệnh *"Found checkpoint: .../checkpoint-600. Resuming training..."*. Điều này cho thấy chiến lược lưu điểm kiểm tra định kỳ đã cứu vãn tiến trình. Thay vì phải huấn luyện lại từ đầu 7000 câu ViMQ do lỗi ngắt kết nối, mô hình tự động nạp lại trọng số tại bước thứ 600 và tiếp tục nối ghép đạo hàm.
- **Thời gian thực thi:** Tổng thời gian huấn luyện đạt 8,633 giây với tốc độ xử lý 0.81 mẫu/giây. Đây là một tốc độ xuất sắc khi xét đến việc phần cứng chỉ sử dụng GPU ảo trên nền tảng miễn phí, khẳng định việc lượng hóa 4-bit và Batch Size nhỏ đã tối ưu hóa tối đa băng thông I/O của phần cứng đám mây.

3.2.5. Kết quả thực nghiệm trên bộ dữ liệu ViMQ

Tập dữ liệu ViMQ ghi nhận hiệu năng trích xuất thực thể rất khả quan. Bảng 3.1 trình bày phân bố các ca lỗi và chỉ số tổng hợp do hệ thống Giám khảo LLM xuất ra.

Bảng 3.1: Phân bố kết quả và Chỉ số đánh giá trên tập ViMQ

Phân loại kết quả	Số lượng	Hệ chỉ số	Precision	Recall	F1-Score
Khớp hoàn toàn (Exact)	1368	Khắt khe (Strict)	0.7496	0.7672	0.7583
Khớp một phần (Partial)	229	Nới lỏng (Relaxed)	0.8751	0.8957	0.8853
Bỏ sót (Missing - FN)	117	<i>Nhận xét: Precision và Recall bám sát nhau, mô hình đạt độ cân bằng cao trên tập ViMQ.</i>			
Nhận diện sai (Spurious)	159				
Sai nhãn (Type Error)	69				

Phân tích phân bố lỗi: Kết quả cho thấy mô hình hoạt động cực kỳ ổn định trên tập ViMQ. Tỷ lệ bỏ sót và đoán thừa duy trì ở mức thấp so với tổng số lượng thực thể được trích xuất thành công. Điểm số cụ thể của các bộ chỉ số

đánh giá được minh họa trực quan trực tiếp tại các phần đối chiếu biểu đồ ở mục sau.

3.2.5.1. Kết quả thực nghiệm trên bộ dữ liệu ViMedNER

Khi chuyển sang tập dữ liệu ViMedNER, độ phức tạp của bài toán tăng lên rõ rệt, phản ánh qua sự sụt giảm của các chỉ số hiệu năng được tóm tắt tại Bảng 3.2.


Bảng 3.2: Phân bố kết quả và Chỉ số đánh giá trên tập ViMedNER

Phân loại kết quả	Số lượng	Hệ chỉ số	Precision	Recall	F1-Score
Khớp hoàn toàn (Exact)	2087	Khắt khe (Strict)	0.6328	0.5881	0.6096
Khớp một phần (Partial)	341	Nới lỏng (Relaxed)	0.7362	0.6841	0.7092
Bỏ sót (Missing - FN)	865	<i>Nhận xét: Lượng Missing và Spurious tăng vọt, chỉ số Recall suy giảm mạnh so với Precision.</i>			
Nhận diện sai (Spurious)	614				
Sai nhãn (Type Error)	256				

Biện luận nguyên nhân phân mảnh lỗi: Điểm đáng chú ý nhất là số lượng thực thể bị bỏ sót tăng vọt lên mức 865, kéo theo điểm Recall khắt khe tụt xuống chỉ còn 0.5881. Sự biến động này xuất phát từ bản chất của bộ dữ liệu chứa nhiều cấu trúc liệt kê bệnh lý lồng nhau phức tạp. Khi đối mặt với chuỗi ngữ nghĩa rườm rà, LLM có xu hướng bỏ sót các thực thể ẩn hoặc tự cố gắng cắt nghĩa sai lệch.


3.2.6. Thảo luận và Đánh giá so sánh

Để có góc nhìn toàn diện và trực quan nhất về sự chênh lệch hiệu năng giữa hai tập dữ liệu y tế, nghiên cứu tiến hành phân tích biểu đồ đối chiếu ba chỉ số Precision, Recall và F1-Score dưới hai điều kiện kiểm định khác nhau.




Hình 3.2: So sánh bộ chỉ số đánh giá Strict Metrics

Như được thể hiện rõ nét tại Hình 3.2, khi áp dụng thang đo khắt khe tương tự chuẩn Segeval truyền thống, hiệu năng trên tập ViMQ vượt trội hơn hẳn tập ViMedNER ở cả ba chỉ số. Trong đó, Recall của ViMedNER bị suy giảm nghiêm trọng nhất chỉ đạt 0.5881, minh chứng cho thấy rào cản lớn của mô hình khi đối mặt với văn phong bệnh án chuyên sâu.



Hình 3.3: So sánh bộ chỉ số đánh giá Relaxed Metrics

Ngược lại, khi chuyển sang lăng kính đánh giá ngữ nghĩa lâm sàng tại Hình 3.3, điểm F1-Score của cả hai tập dữ liệu đều tăng trung bình hơn 10% (ViMQ đạt tới 0.8853 và ViMedNER tiệm cận mức 0.7092). Sự tăng trưởng đồng đều này khẳng định mô hình trên thực tế đã nắm bắt rất tốt bản chất thực thể y khoa cốt lõi, phần lớn điểm bị trừ ở thang đo Strict chỉ là do sự lệch biên ký tự từ vựng ở các rìa dấu câu hoặc liên từ phụ trợ.



Hình 3.4: Biểu đồ phân bố chất lượng và các nhóm lỗi dự đoán thực thể của mô hình

Sự phân bố chi tiết cấu trúc các nhóm lỗi và tỷ lệ dự đoán đúng được chuẩn hóa trực quan bằng biểu đồ cột chồng tại Hình 3.4. Biểu đồ bộc lộ rõ tỷ lệ khớp hoàn toàn chiếm phần lớn trong tổng số thực thể mà mô hình nhả ra. Tuy nhiên, tỷ lệ lỗi nhận diện thừa và sai nhãn phân loại của tập ViMedNER phình to hơn rõ rệt so với ViMQ.

Điều này mang lại một đóng góp thực tiễn lớn cho nghiên cứu: Khẳng định phương pháp sử dụng LLM làm giám khảo thông minh đã định lượng hóa và phân rã thành công các phân khúc lỗi hạt mịn mà các khung mẫu truyền thống cứng nhắc trước đây hoàn toàn bị "điểm mù", giúp người phát triển hệ thống biết chính xác mô hình đang gặp lỗi ở phân đoạn nào để tiến hành tối ưu hóa tiền xử lý dữ liệu trong tương lai.

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Tổng kết những kết quả đạt được

Nghiên cứu này đã triển khai thành công hệ thống Nhận dạng thực thể có tên (NER) trong lĩnh vực y tế tiếng Việt bằng cách tiếp cận hướng sinh (Generative NER) dựa trên mô hình ngôn ngữ lớn Qwen2.5-3B-Instruct. Qua quá trình tổng hợp cơ sở lý thuyết và tiến hành thực nghiệm chi tiết, nghiên cứu đã đạt được những kết quả nổi bật sau:

- **Khả năng định tính ưu việt của kỹ thuật QLoRA:** Bằng việc kết hợp lượng tử hóa 4-bit (NF4) và phương pháp thích nghi ma trận hạng thấp (LoRA), hệ thống đã tinh chỉnh thành công mô hình với hơn 3,1 tỷ tham số trên hạ tầng phần cứng giới hạn. Tỷ lệ tham số cần huấn luyện chỉ chiếm xấp xỉ 0,96% (khoảng 29,9 triệu tham số), giúp giảm tải đáng kể áp lực bộ nhớ trong khi vẫn duy trì sự ổn định của hàm mất mát (loss hội tụ ở mức 0,045 trên tập kiểm định) và ngăn chặn hoàn toàn hiện tượng học vẹt (overfitting).
- **Xây dựng luồng tiền xử lý và hậu xử lý dữ liệu mạnh mẽ:** Nghiên cứu đã thiết kế một hệ thống bộ lọc đa tầng nhằm giải quyết triệt để bài toán "ảo giác" (hallucination) cấu trúc của LLM. Các cơ chế cắt tỉa thể định dạng, bắt lỗi ngoại lệ JSON và sàng lọc schema y tế đã chuẩn hóa thành công đầu ra tự do của LLM về định dạng có cấu trúc nghiêm ngặt, phục vụ tốt cho quy trình đối sánh.
- **Đánh giá toàn diện trên đa ngữ cảnh y khoa:** Việc tiến hành thực nghiệm song song trên hai bộ dữ liệu ViMQ (câu hỏi ngắn) và ViMedNER (bệnh án chuyên sâu) đã phác họa rõ nét biên độ năng lực của mô hình. Trong khi mô hình đạt hiệu năng rất cao và cân bằng trên tập ViMQ (Strict F1-Score đạt 0,7583), hệ thống cũng bộc lộ những giới hạn khi xử lý các chuỗi liệt kê phức tạp trong ViMedNER.
- **Tiên phong áp dụng cơ chế đánh giá linh hoạt (LLM-as-a-Judge):** Thay vì chỉ phụ thuộc vào khung đánh giá Exact Match truyền thống cứng nhắc, nghiên cứu đã đưa vào áp dụng hệ chỉ số Relaxed Match ($\text{IoU} \geq 0,5$). Kết quả F1-Score tăng trung bình hơn 10% ở cả hai bộ dữ liệu đã chứng minh rằng mô hình thực chất có khả năng nhận thức ngữ nghĩa y khoa rất tốt, và các lỗi sai chủ yếu đến từ sự lệch biên ký tự (dấu câu, liên từ) chứ không phải do sai lệch kiến thức cốt lõi.

Những hạn chế còn tồn tại

Bên cạnh các kết quả tích cực, phân tích lỗi (Error Analysis) từ thực nghiệm cũng chỉ ra một số điểm nghẽn cần khắc phục trong hệ thống hiện tại:

- **Sự sụt giảm hiệu năng trước cấu trúc văn bản phức tạp:** Trên tập dữ liệu ViMedNER, tỷ lệ bỏ sót thực thể (Missing/False Negative) tăng vọt, kéo chỉ số Strict Recall xuống mức 0,5881. LLM gặp khó khăn lớn trong việc phân tách các thực thể lồng ghép hoặc các cấu trúc liệt kê bệnh lý rườm rà mang tính mô tả dài hạn.
- **Độ nhạy cảm với ranh giới từ vựng:** Mô hình sinh văn bản thường có xu hướng bao gồm cả các mạo từ, giới từ hoặc dấu câu vào bên trong span thực thể. Dù đã có luồng hậu xử lý, việc xác định ranh giới (boundary) tuyệt đối chính xác như các mô hình gán nhãn chuỗi (sequence labeling) truyền thống vẫn là một thách thức đối với cách tiếp cận Generative NER.
- **Hạn chế về tài nguyên phần cứng thời gian thực:** Tốc độ suy luận 0,81 mẫu/giây trên phần cứng đám mây là mức khả quan cho việc nghiên cứu, nhưng sẽ trở thành rào cản về độ trễ (latency) nếu triển khai hệ thống này vào các phần mềm bệnh án điện tử đòi hỏi phản hồi tức thì.

Hướng phát triển tương lai

Từ các kết quả thực nghiệm và những giới hạn đã phân tích, nghiên cứu đề xuất một số hướng phát triển tiếp theo để hoàn thiện và nâng cấp hệ thống:

- **Tối ưu hóa kỹ thuật Prompt Engineering và Dữ liệu huấn luyện:** Cải tiến các chỉ dẫn (instructions) để buộc LLM phải tuân thủ nghiêm ngặt ranh giới ký tự. Đồng thời, cần bổ sung thêm các mẫu dữ liệu huấn luyện chứa các thực thể lồng nhau (nested entities) để tăng cường sức đề kháng của mô hình trước các câu văn phức tạp.
- **Nghiên cứu các kiến trúc mô hình nội địa hóa:** Thử nghiệm tinh chỉnh trên các mô hình ngôn ngữ lớn được huấn luyện chuyên sâu cho tiếng Việt (như VinaLLaMA hoặc PhoGPT) nhằm tận dụng nguồn tri thức ngôn ngữ bản địa, thay vì chỉ phụ thuộc vào khả năng đa ngôn ngữ của các mô hình quốc tế như Qwen.
- **Phát triển hệ thống hiệu chỉnh tự động (Auto-Correction):** Nâng cấp vai trò của *LLM-as-a-Judge* không chỉ dừng lại ở mức độ giám khảo đánh giá và phân loại lỗi, mà còn đóng vai trò là một module "Self-Reflect" (Tự phản tỉnh), cho phép hệ thống tự động sinh lại hoặc tinh chỉnh ranh giới span ngay khi phát hiện dự đoán có dấu hiệu ảo giác hoặc sai lệch cấu trúc y khoa.

TÀI LIỆU THAM KHẢO

- [1] Improving Automatic Evaluation of Large Language Models (LLMs) in Biomedical Relation Extraction via LLMs-as-the-Judge